



SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU

FAKULTET PRIMIJENJENE MATEMATIKE I INFORMATIKE

Sveučilišni preddiplomski studij Matematika i računarstvo

Simulacija upravljanja dvostrukim obrnutim njihalom na kolicima

ZAVRŠNI RAD

Mentor:

**izv. prof. dr. sc.
Zoran Tomljanović**

**doc. dr. sc.
Matea Ugrica Vukojević**

Kandidat:

Luka Kurtović

Osijek, 2026

Sadržaj

1	Uvod	1
2	Pretpostavke modela i oznake	3
2.1	Pretpostavke modela	3
2.2	Oznake	4
3	Matematički model i linearizacija sustava	5
3.1	Nelinearni model sustava	5
3.2	Linearizacija oko uspravne ravnoteže	6
3.3	Prikaz u prostoru stanja	6
4	Upravlјivost sustava	9
5	Polovi sustava	11
6	Regulacija stanja	13
6.1	Opći princip: povratna veza po stanju	13
6.2	Zatvorena petlja	13
7	LQR regulator	15
7.1	Formulacija LQR problema	15
7.2	Rješavanje algebarske Riccatijeve jednadžbe	16
7.3	Usporedba otvorene i zatvorene petlje	16
7.4	Provjera na punom nelinearnom modelu	17
8	Simulacija na nelinearnom modelu i rezultati	19
8.1	Postavljanje simulacije	19
8.2	Rezultati simulacije	22
8.2.1	Sustav bez regulatora	22
8.2.2	Mali početni otklon: 1°	23
8.2.3	Umjeren početni otklon: 10°	24
8.2.4	Velik početni otklon: 20°	25
8.3	Zaključak simulacije	25
	Literatura	27
	Sažetak	29

Summary	31
Životopis	33

1 | Uvod

Cilj ovoga rada je izraditi simulaciju upravljanja dvostrukim obrnutim njihalom na pokretnim kolicima, sposobnu stabilizirati sustav u uspravnom ravnotežnom položaju.


Problem stabilizacije njihala u uspravnom položaju jedan je od klasičnih problema u teoriji upravljanja. Kada se na kolica koja se gibaju vodoravno postavi jedan štap, dobije se obrnuto njihalo na kolicima. Dodavanjem još jednog, zglobno povezanog štapa dobiva se dvostruko obrnuto njihalo na kolicima. U ovom radu dvostruko obrnuto njihalo na kolicima želi se dovesti u uspravno ravnotežno stanje djelujući isključivo na kolica. Ovakvi se modeli koriste i u praktičnim primjenama. Upravo se dvostruko njihalo može koristiti za modeliranje hodanja robota. Zamašna noga tijekom faze oslonca na drugoj nozi standardno se modelira kao dvostruko njihalo, pri čemu bedrena kost i potkoljenica odgovaraju njegovim štapovima, a kuk i koljeno zglobovima koji ih povezuju s tijelom. Sustav je nelinearan, njegovo uspravno ravnotežno stanje prirodno je nestabilno, a djelovati možemo isključivo silom na kolica, dok se oba štapa njišu slobodno.

Prvo se razmatra nelinearni model sustava preuzet iz nastavnog materijala [2]. Zatim se taj model linearizira oko uspravnog ravnotežnog stanja i zapisuje u standardnom obliku prostora stanja. Nad dobivenim linearnim modelom potom se provjerava upravljivost sustava i analiziraju polovi. Tada se uvodi opći princip regulacije povratnom vezom po stanju te dizajnira konkretan regulator. Djelovanje dobivenog regulatora naposljetku se provjerava na punom nelinearnom modelu sustava.

2 | Pretpostavke modela i oznake

2.1 Pretpostavke modela

Polazni nelinearni fizikalni model sustava u potpunosti je opisan u nastavnom materijalu [2], gdje je izveden Lagrangeovom mehanikom. U ovom radu taj se model preuzima kao fizikalna osnova, dok se za opći teorijski okvir i notaciju linearnih sustava upravljanja (prostor stanja, matrice A,B,E, pojam upravljivosti i stabilnosti) koristi knjiga Linear Systems Theory Joãoa P. Hespanhe [1]. U poglavljima koja slijede model iz [2] se stoga prevodi iz njegove izvorne notacije u standardni oblik prostora stanja kakav koristi [1], čime postaje pogodan za primjenu alata za analizu i dizajn regulatora opisanih u toj skripti.



Slika 2.1: Shematski prikaz dvostrukog obrnutog njihala na kolicima, preuzeto iz [2].

Fizikalni sustav opisan u [2] sastoji se od kolica mase m koja se mogu gibati isključivo vodoravno, na koje je zglobovno pričvršćen prvi, štapić duljine l_1 s koncentriranom masom m_1 na vrhu. Na vrh prvog štapića (koji je ujedno i dno drugog) zglobovno je pričvršćen drugi štapić duljine l_2 s koncentriranom masom m_2 na vrhu. Kutevi θ_1 i θ_2 mjere otklon pojedinog štapića od uspravnog (okomitog) položaja, kako je prikazano na Slici 2.1. Sustavom se upravlja isključivo silom u koja djeluje na kolica, dok w_1, w_2, w_3 predstavljaju vanjske smetnje (npr. vjetar ili gurkanje) koje djeluju na kolica i oba zgloba. d_1, d_2, d_3 predstavljaju koeficijente trenja kolica i oba zgloba.

2.2 Oznake

Fizikalni sustav i njegove veličine opisani su sljedećim oznakama.

Oznaka	Značenje
m	masa kolica
m_1	masa na vrhu prvog štapa
m_2	masa na vrhu drugog štapa
l_1	duljina prvog štapa
l_2	duljina drugog štapa
q	vodoravni položaj kolica
θ_1	kut otklona prvog štapa od okomice
θ_2	kut otklona drugog štapa od okomice
d_1, d_2, d_3	koeficijenti trenja (kolica, prvi zglobov, drugi zglobov)
u	upravljačka sila na kolica
w_1, w_2, w_3	vanjske smetnje (sile na q, θ_1, θ_2)
g	gravitacijsko ubrzanje

Poopćene koordinate, upravljački ulaz i vanjske smetnje sustava definirani su vektorima:

$$y = \begin{bmatrix} q \\ \theta_1 \\ \theta_2 \end{bmatrix}, \quad u \text{ (sila na kolica)}, \quad w = \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}$$

Ravnotežni (uspravni) položaj sustava, oko kojeg će se kasnije provoditi linearizacija, dan je s (kolica mogu mirovati u bilo kojem položaju q_0 , pa je taj položaj proizvoljan):

$$y_0 = \begin{bmatrix} q_0 \\ 0 \\ 0 \end{bmatrix}$$

Budući da su jednadžbe gibanja drugog reda (sadrže $\ddot{y}$), stanje sustava mora obuhvatiti i položaj i brzinu; definira se vektor stanja:

$$x = \begin{bmatrix} y \\ \dot{y} \end{bmatrix} = \begin{bmatrix} q \\ \theta_1 \\ \theta_2 \\ \dot{q} \\ \dot{\theta}_1 \\ \dot{\theta}_2 \end{bmatrix} \in \mathbb{R}^6$$

3 | Matematički model i linearizacija sustava

Kako bismo mogli upravljati sustavom, potrebno je prvo razumjeti nelinearni model $M(y)\ddot{y} = f(y, \dot{y}, u, w)$, a zatim ga linearizirati u oblik $\dot{x} = Ax + Bu + Ew$ oko uspravne ravnoteže. Alati za dizajn regulatora (koje koristimo u narednim poglavljima) primjenjivi su isključivo na linearnim modelima.

3.1 Nelinearni model sustava

Kao što je opisano u Poglavlju 2, primjenom Lagrangeove mehanike na sustav prikazan na Slici 2.1 dobivaju se jednačbe gibanja u matričnom obliku:

$$M(y)\ddot{y} = f(y, \dot{y}, u, w) \quad (3.1)$$

gdje je $M(y)$ matrica mase sustava:

$$M(y) = \begin{bmatrix} m + m_1 + m_2 & l_1(m_1 + m_2) \cos \theta_1 & m_2 l_2 \cos \theta_2 \\ l_1(m_1 + m_2) \cos \theta_1 & l_1^2(m_1 + m_2) & l_1 l_2 m_2 \cos(\theta_1 - \theta_2) \\ l_2 m_2 \cos \theta_2 & l_1 l_2 m_2 \cos(\theta_1 - \theta_2) & l_2^2 m_2 \end{bmatrix},$$

a $f(y, \dot{y}, u, w)$ vektor koji predstavlja sve sile (odnosno poopćene sile) koje djeluju na sustav - gravitacijske i centrifugalne sile, sile trenja, upravljačku silu te vanjske smetnje:

$$f(y, \dot{y}, u, w) = \begin{bmatrix} l_1(m_1 + m_2)\dot{\theta}_1^2 \sin \theta_1 + m_2 l_2 \dot{\theta}_2^2 \sin \theta_2 \\ -l_1 l_2 m_2 \dot{\theta}_2^2 \sin(\theta_1 - \theta_2) + g(m_1 + m_2) l_1 \sin \theta_1 \\ l_1 l_2 m_2 \dot{\theta}_1^2 \sin(\theta_1 - \theta_2) + g l_2 m_2 \sin \theta_2 \end{bmatrix} - \begin{bmatrix} d_1 \dot{q} \\ d_2 \dot{\theta}_1 \\ d_3 \dot{\theta}_2 \end{bmatrix} + \begin{bmatrix} u \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}.$$

Matrica $M(y)$ je invertibilna za sve y [2], pa se jednačba (3.1) može zapisati u eksplicitnom obliku $\ddot{y} = M^{-1}(y)f(y, \dot{y}, u, w)$, pogodnom za numeričku integraciju. Za dizajn regulatora potreban je linearni model, pa sustav u nastavku lineariziramo.

3.2 Linearizacija oko uspravne ravnoteže

Za male kuteve odklona θ_1, θ_2 i male kutne brzine vrijede sljedeće aproksimacije prvog reda:

$$\sin \theta_i \approx \theta_i, \quad \cos \theta_i \approx 1, \quad \dot{\theta}_1^2, \dot{\theta}_2^2, \dot{\theta}_1 \dot{\theta}_2 \approx 0$$

Primjenom ovih aproksimacija matrica mase $M(y)$ postaje konstantna matrica M_0 (ovisna isključivo o masama i duljinama):

$$M_0 = \begin{bmatrix} m + m_1 + m_2 & l_1(m_1 + m_2) & m_2 l_2 \\ l_1(m_1 + m_2) & l_1^2(m_1 + m_2) & l_1 l_2 m_2 \\ l_2 m_2 & l_1 l_2 m_2 & l_2^2 m_2 \end{bmatrix}$$

Primjenom istih aproksimacija na vektor $f(y, \dot{y}, u, w)$, svi članovi koji sadrže $\dot{\theta}_1^2$, $\dot{\theta}_2^2$ ili $\dot{\theta}_1 \dot{\theta}_2$ nestaju, dok preostali $\sin \theta_i$ članovi prelaze u θ_i .

$$f_{lin}(y, \dot{y}, u, w) = \begin{bmatrix} 0 \\ g(m_1 + m_2)l_1 \theta_1 \\ gl_2 m_2 \theta_2 \end{bmatrix} - \begin{bmatrix} d_1 \dot{q} \\ d_2 \dot{\theta}_1 \\ d_3 \dot{\theta}_2 \end{bmatrix} + \begin{bmatrix} u \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}$$

Prvi član desne strane prepoznaje se kao umnožak konstantne matrice S i vektora y , drugi kao umnožak dijagonalne matrice trenja D i vektora $\dot{y}$, a treći kao umnožak vektora B_u i skalara u :

$$\begin{aligned} f_{lin}(y, \dot{y}, u, w) = & \underbrace{\begin{bmatrix} 0 & 0 & 0 \\ 0 & g(m_1 + m_2)l_1 & 0 \\ 0 & 0 & gl_2 m_2 \end{bmatrix}}_S \underbrace{\begin{bmatrix} q \\ \theta_1 \\ \theta_2 \end{bmatrix}}_y - \underbrace{\begin{bmatrix} d_1 & 0 & 0 \\ 0 & d_2 & 0 \\ 0 & 0 & d_3 \end{bmatrix}}_D \underbrace{\begin{bmatrix} \dot{q} \\ \dot{\theta}_1 \\ \dot{\theta}_2 \end{bmatrix}}_{\dot{y}} \\ & + \underbrace{\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}}_{B_u} \underbrace{u}_u + \underbrace{\begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}}_w. \end{aligned}$$

Uvrštavanjem ovog lineariziranog f_{lin} natrag u jednadžbu gibanja (3.1) (uz $M(y) \rightarrow M_0$ kako je pokazano ranije), dobiva se potpuno linearna jednadžba (bez trigonometrijskih funkcija i kvadratnih članova), no i dalje drugog reda te pomnožena matricom M_0 :

$$M_0 \ddot{y} = S y - D \dot{y} + B_u u + w \quad (3.2)$$

3.3 Prikaz u prostoru stanja

M_0 je regularna matrica što slijedi iz invertibilnosti $M(y)$ za sve y , pokazane u [2]. Množenjem jednadžbe (3.2) s lijeva inverzom matrice M_0^{-1} izolira se najviša derivacija $\ddot{y}$:

$$\ddot{y} = M_0^{-1} S y - M_0^{-1} D \dot{y} + M_0^{-1} B_u u + M_0^{-1} w$$

Inverz M_0^{-1} izračunat je simbolički (WolframAlpha) u zatvorenom obliku:

$$M_0^{-1} = \begin{bmatrix} \frac{1}{m} & -\frac{1}{l_1 m} & 0 \\ -\frac{1}{l_1 m} & \frac{m+m_1}{l_1^2 m m_1} & -\frac{1}{l_1 l_2 m_1} \\ 0 & -\frac{1}{l_1 l_2 m_1} & \frac{m_1+m_2}{l_2^2 m_1 m_2} \end{bmatrix}$$

Izoliranjem najviše derivacije u jednadžbi (3.2) (množenjem s lijeva sa M_0^{-1}) dobiva se

$$\ddot{y} = M_0^{-1} S y - M_0^{-1} D \dot{y} + M_0^{-1} B_u u + M_0^{-1} w. \quad (3.3)$$

Uvodi se vektor stanja $x = [y; \dot{y}] \in \mathbb{R}^6$ (definiran u Poglavlju 2), odnosno raspisano po komponentama:

$$x = \begin{bmatrix} y \\ \dot{y} \end{bmatrix} = \begin{bmatrix} q \\ \theta_1 \\ \theta_2 \\ \dot{q} \\ \dot{\theta}_1 \\ \dot{\theta}_2 \end{bmatrix} \in \mathbb{R}^6.$$

Njegova derivacija po vremenu je

$$\dot{x} = \begin{bmatrix} \dot{y} \\ \ddot{y} \end{bmatrix},$$

gdje je gornji blok, $\dot{y}$, po samoj definiciji vektora stanja već poznat, a donji blok, $\ddot{y}$, dan je upravo jednadžbom (3.3). Uvrštavanjem dobivamo:

$$\dot{x} = \begin{bmatrix} \dot{y} \\ M_0^{-1} S y - M_0^{-1} D \dot{y} + M_0^{-1} B_u u + M_0^{-1} w \end{bmatrix}$$

Ovaj izraz sada grupiramo po x , u te w :

$$\dot{x} = \underbrace{\begin{bmatrix} 0_{3 \times 3} & I_{3 \times 3} \\ M_0^{-1} S & -M_0^{-1} D \end{bmatrix}}_A \begin{bmatrix} y \\ \dot{y} \end{bmatrix} + \underbrace{\begin{bmatrix} 0 \\ M_0^{-1} B_u \end{bmatrix}}_B u + \underbrace{\begin{bmatrix} 0 \\ M_0^{-1} \end{bmatrix}}_E w$$

Time je jednadžba drugog reda po y svedena na jednadžbu prvog reda po x , u standardnom obliku prostora stanja:

$$\dot{x} = Ax + Bu + Ew, \quad (3.4)$$

gdje su matrice A, B, E prepoznate gore:

$$A = \begin{bmatrix} 0_{3 \times 3} & I_{3 \times 3} \\ M_0^{-1} S & -M_0^{-1} D \end{bmatrix}, \quad B = \begin{bmatrix} 0 \\ M_0^{-1} B_u \end{bmatrix}, \quad E = \begin{bmatrix} 0 \\ M_0^{-1} \end{bmatrix}.$$

Promjena stanja sustava jednaka je, dakle, linearnoj kombinaciji trenutnog stanja, upravljačke sile i vanjskih smetnji. Ovaj model predstavlja polaznu točku za sve daljnje analize sustava: provjeru upravljivosti, analizu polova, te dizajn regulatora stanja.

4 | Upravlјivost sustava

Prije nego što krenemo u dizajn regulatora, potrebno je utvrditi je li sustav dobi-
ven u Poglavlju 3 uopće *upravlјiv*. Ovo je pitanje posebno relevantno jer sustav
ima samo jedan upravlјački ulaz (silu na kolica), dok stanje ima šest komponenti
 $x = [q, \theta_1, \theta_2, \dot{q}, \dot{\theta}_1, \dot{\theta}_2]^T$. Potrebno je provjeriti može li ta jedna sila, posredstvom
mehaničke sprege između kolica i oba štapa (kolica vuku prvi štap, prvi štap vuče
drugi), utjecati na sve komponente stanja, ili neka od njih ostaju "izvan dohvata".

Definicija 1 (vidjeti [4, Definicija 1.2]). Sustav $\dot{x} = Ax + Bu$ (poseban, vremenski
nepromjenjiv slučaj opće definicije za linearne vremenski promjenjive upravlјačke sustave)
je **upravlјiv** na $[T_0, T_1]$ ako za svaka dva stanja $x_0, x_1 \in \mathbb{R}^n$ postoji upravlјačka funkcija
 $u \in L^\infty([T_0, T_1]; \mathbb{R}^m)$ takva da rješenje $x \in C^0([T_0, T_1]; \mathbb{R}^n)$ jednadžbe $\dot{x} = Ax + Bu$,
uz početni uvjet $x(T_0) = x_0$, zadovoljava $x(T_1) = x_1$.

Drugim riječima, sustav je upravlјiv ako se silom u može, u konačnom vre-
menu, dovesti iz bilo kojeg početnog stanja u bilo koje ciljano stanje.

Teorem 1 (vidjeti [4, Teorem 1.16]). Vremenski invarijantan linearni sustav upravlјa-
nja $\dot{x} = Ax + Bu$ je upravlјiv na $[T_0, T_1]$ ako i samo ako

$$\text{Span}\{A^i Bu ; u \in \mathbb{R}^m, i \in \{0, \dots, n-1\}\} = \mathbb{R}^n.$$

Štoviše, za bilo koje $T_0 < T_1$ i $\tilde{T}_0 < \tilde{T}_1$, sustav $\dot{x} = Ax + Bu$ kontrolabilan je na $[T_0, T_1]$
ako i samo ako je kontrolabilan na $[\tilde{T}_0, \tilde{T}_1]$.

Ovaj rezultat u literaturi je poznat i kao Kalmanov rang uvjet kontrolabilnosti [3].

Uvjet iz teorema može se zapisati i u praktičnijem, ekvivalentnom obliku. Kad
 u prođe kroz cijeli $\mathbb{R}^m$, izraz $A^i Bu$ prolazi kroz sliku matrice $A^i B$, pa je $\text{Span}\{A^i Bu : u \in \mathbb{R}^m\} = \text{Im}(A^i B)$. Skup svih vektora oblika $A^0 Bu_0 + A^1 Bu_1 + \dots + A^{n-1} Bu_{n-1}$,
za proizvoljne $u_0, \dots, u_{n-1} \in \mathbb{R}^m$, jednak je stoga zbroju potprostora $\text{Im}(B) + \text{Im}(AB) + \dots + \text{Im}(A^{n-1}B)$. Standardno svojstvo linearne algebre kaže da je taj
zbroj slika jednak slici matrice dobivene vodoravnim nadovezivanjem (spajanjem
stupaca) svih tih matrica. Stoga definira se upravlјiva matrica

$$C := [B \quad AB \quad A^2B \quad \dots \quad A^{n-1}B] \in \mathbb{R}^{n \times (nm)},$$

pa je uvjet iz Teorema 1 ekvivalentan sa $\text{Im}(C) = \mathbb{R}^n$, odnosno (budući da je rang
matrice definiran kao dimenzija njene slike) s

$$\text{rank}(C) = n.$$

U nastavku rada koristi se upravo ovaj oblik uvjeta, jer je lakši za provjeru. Primijetimo da se pri konstrukciji matrice $\mathcal{C}$ koristi isključivo par (A, B) ; matrica E (kojom u model ulaze vanjske smetnje w) ne sudjeluje u provjeri upravljivosti, jer smetnje nisu veličina kojom mi upravljamo.

Za probne vrijednosti fizikalnih parametara

$$\begin{aligned} m &= 1.0, \quad m_1 = 0.3, \quad m_2 = 0.2, \quad l_1 = 0.3, \quad l_2 = 0.25, \\ d_1 &= 0.1, \quad d_2 = 0.05, \quad d_3 = 0.05, \quad g = 9.81, \end{aligned}$$

singularne vrijednosti upravljive matrice $\mathcal{C}$ (izračunate u Pythonu, funkcijom `numpy.linalg.svd`) iznose

$$\sigma_1 \approx 1.00 \times 10^6, \quad \sigma_2 \approx 4491, \quad \sigma_3 \approx 165, \quad \sigma_4 \approx 8.56, \quad \sigma_5 \approx 0.685, \quad \sigma_6 \approx 0.639.$$

Budući da su sve singularne vrijednosti strogo pozitivne, rang matrice $\mathcal{C}$ jednak je $\text{rank}(\mathcal{C}) = 6$ (izračunato funkcijom `numpy.linalg.matrix_rank`, koja rang određuje upravo brojanjem singularnih vrijednosti iznad numeričke granice). Sustav je za navedene parametre potpuno upravljiv, prema Teoremu 1.

5 | Polovi sustava

Svojstvene vrijednosti matrice A sustava $\dot{x} = Ax$ nazivaju se **polovima** tog sustava. U ovom se radu pojmovi "pol" i "svojstvena vrijednost matrice A " koriste kao istoznačnice.

Teorem 2 (Teorem 8.1, vidjeti [1, poglavlje 8.3]). *Sustav $\dot{x} = Ax$ je asimptotski stabilan ako i samo ako svi polovi (svojstvene vrijednosti) matrice A imaju strogo negativan realni dio.*

Za probne vrijednosti parametara iz Poglavlja 4, numerički izračunate svojstvene vrijednosti matrice A iznose:

$$\lambda_1 = 0, \quad \lambda_2 = -14.574, \quad \lambda_3 = -6.555, \quad \lambda_4 = 7.608, \quad \lambda_5 = 4.414, \quad \lambda_6 = -0.067.$$

Sustav $\dot{x} = Ax + Bu + Ew$ bez upravljanja ($u = 0$) je, prema Teoremu 2, **nestabilan** – matrica A ima dvije svojstvene vrijednosti sa strogo pozitivnim realnim dijelom (λ_4 i λ_5), pa nisu **sve** svojstvene vrijednosti strogo negativnog realnog dijela. Ovo odgovara obrnutom njihalu koje samo od sebe pada. U nastavku rada (Poglavlje 6) ovaj se nedostatak ispravlja uvođenjem regulatora, koji djelovanjem na upravljačku silu u pomiče polove zatvorene petlje tako da svi imaju strogo negativan realni dio, čime se sustav stabilizira.

6 | Regulacija stanja

6.1 Opći princip: povratna veza po stanju

Regulator je pravilo po kojem automatski bira upravljački ulaz u na temelju trenutnog stanja sustava, kako bismo tu nestabilnost ispravili. Opći princip pritom je *povratna veza po stanju* (state feedback) [1, poglavlje 10.4]:

$$u = -Kx \quad (6.1)$$

gdje je $K \in \mathbb{R}^{1 \times 6}$ red od šest brojeva (pojaćanja), po jedan za svaku komponentu stanja $x = [q, \theta_1, \theta_2, \dot{q}, \dot{\theta}_1, \dot{\theta}_2]^T$:

$$u = -(k_1 q + k_2 \theta_1 + k_3 \theta_2 + k_4 \dot{q} + k_5 \dot{\theta}_1 + k_6 \dot{\theta}_2).$$

Regulator u svakom trenutku "gleda" cijelo stanje sustava i računa silu koja ga gura natrag prema ravnoteži.

6.2 Zatvorena petlja

Uvrštavanjem zakona upravljanja (6.1) u jednadžbu sustava (3.4) (bez vanjske smetnje, $w = 0$) dobivamo:

$$\dot{x} = Ax + Bu = Ax + B(-Kx) = Ax - BKx = \underbrace{(A - BK)}_{=: A_{cl}} x. \quad (6.2)$$

Dobili smo novi sustav, s novom matricom $A_{cl} := A - BK$ ("cl" = closed loop). Cijeli je zadatak dizajna regulatora odabrati brojeve u K tako da A_{cl} bude stabilna matrica:

$$\dot{x} = A_{cl}x \text{ je stabilan} \iff \text{svi polovi od } A_{cl} \text{ imaju } \operatorname{Re}(\lambda) < 0.$$

Bitna napomena: preduvjet da takav K uopće postoji jest upravljivost para (A, B) , koju smo već pokazali u Poglavlju 4 (Teorem 1).

Preostaje pitanje kako konkretno odabrati brojeve unutar K tako da A_{cl} zaista bude stabilna matrica. U nastavku rada taj se izbor provodi metodom linearno-kvadratne regulacije (LQR), opisanom u Poglavlju 7, čime se dobiva pojaćanje K koje se uvrštava u jednadžbu zatvorene petlje (6.2).

7 | LQR regulator

U Poglavlju 6 uveden je opći princip povratne veze po stanju $u = -Kx$, no ostalo je otvoreno pitanje kako konkretno odabrati pojačanje K . U ovom poglavlju taj se izbor svodi na rješavanje optimizacijskog problema poznatog kao *linearno-kvadratni regulator* (LQR) [1, poglavlje 10.1].

7.1 Formulacija LQR problema

Tražimo regulator koji minimizira ukupnu "energiju izlaza" i "energiju upravljačkog signala", izraženu funkcionalom cijene:

$$J_{LQR} = \int_0^\infty (x(t)^T Q x(t) + u(t)^T R u(t)) dt \quad (7.1)$$

1

Matrice Q i R *sami biramo* – one određuju koliko strogo penaliziramo odklon pojedine komponente stanja, odnosno utrošak upravljačke sile. Uz $Q = \text{diag}(q_1, \dots, q_6)$ i $x = [q, \theta_1, \theta_2, \dot{q}, \dot{\theta}_1, \dot{\theta}_2]^T$, svaku komponentu stanja kažnjavamo neovisno. U ovom radu odabrano je

$$Q = \text{diag}(1, 100, 100, 1, 10, 10), \quad R = 1,$$

čime su kutevi θ_1, θ_2 (najbitnije veličine za stabilizaciju) penalizirani 100 puta strože od položaja kolica q . Bitni su pritom isključivo omjeri unutar Q u odnosu na R , ne apsolutne vrijednosti – istovremeno skaliranje Q i R istim faktorom daje identično pojačanje K .

Kako bi se opravdao ovaj odabir matrica Q i R , izvršena je usporedba s dvije alternativne varijante, jednom koja kuteve penalizira još strože, i jednom koja štedi upravljačku silu. Na punom nelinearnom modelu, uz početni odklon $\theta_1(0) = 15^\circ$, $\theta_2(0) = -10^\circ$ dobivamo sljedeće:

¹Napomena o notaciji: Hespanha u [1] transponiranje označava apostroфом, x' , umjesto uobičajenog x^T koji koristimo u ovom radu – oznake su ovdje matematički istovjetne jer je $x \in \mathbb{R}^n$. Nadalje, opća LQR formula u [1, poglavlje 10.1] zapisana je preko *reguliranog izlaza* $y = Cx$, gdje se matrica C bira proizvoljno; u ovom se radu koristi poseban slučaj $C = I$ (penalizira se cijelo stanje izravno), pa je regulirani izlaz jednak samom stanju, $y = x$ – ovime se ujedno izbjegava sudar oznake y s već definiranim vektorom poopcenih koordinata $y = [q, \theta_1, \theta_2]^T$ iz Poglavlja 2, pa se u ovom radu umjesto Hespanhinog y dosljedno piše x .

Q, R	$\max \theta_1 $	$\max \theta_2 $	$\max u $	trud $\int u^2 dt$	$t_{\text{smirivanja}}$
$(1, 100, 100, 1, 10, 10), 1$	39.1°	25.6°	77.2 N	475.0	1.86 s
$(1, 500, 500, 1, 20, 20), 1$	37.0°	23.5°	95.1 N	507.5	1.80 s
$(1, 20, 20, 1, 5, 5), 1$	40.4°	26.6°	69.9 N	530.5	2.37 s

Strože penaliziranje kuteva daje tek neznatno poboljšanje (manji maksimalni otkloni, brže smirivanje), no uz osjetno veću potrebnu silu (95.1 N naspram 77.2 N, odnosno 23% više) i veći ukupni trud regulatora. Odabrana varijanta predstavlja razuman kompromis – dovoljno strogo penalizira kuteve da budu prioritet, bez nepotrebnog trošenja upravljačke sile za tek marginalno poboljšanje performansi.

7.2 Rješavanje algebarske Riccatijeve jednadžbe

Teorem 3 (Teorem 10.1, vidjeti [1, poglavlje 10.4]). *Pretpostavimo da postoji simetrično rješenje P algebarske Riccatijeve jednadžbe (ARE)*

$$A^T P + PA + C^T Q C - P B R^{-1} B^T P = 0$$

za koje je $A - B R^{-1} B^T P$ stabilna matrica. Tada zakon upravljanja $u = -Kx$, $K = R^{-1} B^T P$, stabilizira zatvorenu petlju i pritom minimizira LQR kriterij J_{LQR} .

Uz $C = I$ (vidi napomenu o notaciji u prethodnom odjeljku), vrijedi $C^T Q C = Q$, pa se ARE jednadžba iz teorema svodi na oblik korišten u nastavku rada:

$$A^T P + PA + Q - P B R^{-1} B^T P = 0. \quad (7.2)$$

Optimalno rješenje LQR problema, prema Teoremu 3, ima oblik povratne veze po stanju:

$$u = -Kx, \quad K = R^{-1} B^T P, \quad (7.3)$$

gdje je P rješenje jednadžbe (7.2). Primijetimo da je $A - B R^{-1} B^T P = A - BK = A_{cl}$ iz Poglavlja 6. Uvjet teorema time izravno jamči da je dobivena zatvorena petlja stabilna, u skladu s Teoremom 2.

Jednadžba (7.2) se ne rješava ručno, standardni je pristup preko Hamiltonove matrice [6], implementiran u gotovim funkcijama poput `solve_continuous_are` u Pythonu (paket SciPy [7]), koja je i korištena za numerički izračun P , a time i K , u ovom radu.

7.3 Usporedba otvorene i zatvorene petlje

Za probne vrijednosti parametara iz Poglavlja 4, rješavanjem (7.2) dobiveno je pojačanje

$$K = \begin{bmatrix} 1 & -167.3473 & 191.3879 & 2.8852 & -7.9784 & 15.0899 \end{bmatrix}.$$

Svojstvene vrijednosti sustava prije i nakon uvođenja regulatora s ovim K iznose:

Otvorena petlja (bez regulatora)

0, -14.57, -6.55, 7.61, 4.41, -0.067

Zatvorena petlja ($A - BK$)-17.15, $-8.43 \pm 1.47j$, -3.55, $-0.55 \pm 0.43j$

Svi polovi zatvorene petlje imaju $\text{Re}(\lambda) < 0$, pa je, prema Teoremu 2, sustav s ovim regulatorom asimptotski stabilan.

7.4 Provjera na punom nelinearnom modelu

Pojačanje K dizajnirano je na *linearnom* modelu iz Poglavlja 3, koji je tek aproksimacija stvarnog sustava, valjana samo za male kuteve θ_1, θ_2 . Da bismo provjerili djeluje li regulator i na stvarnom, nelinearnom sustavu, isti se K uvrštava natrag u puni nelinearni model iz Poglavlja 3.1:

$$M(y)\ddot{y} = f(y, \dot{y}, u, w),$$

pri čemu se umjesto slobodno odabranog u sada koristi izraz dobiven regulatorom, $u = -Kx$, primijenjen na trenutno (nelinearno) stanje sustava. Rezultati ove provjere prikazani su u poglavlju 8.

Konkretno, budući da se upravljačka sila u u nelinearnom modelu pojavljuje samo u prvoj komponenti vektora $f(y, \dot{y}, u, w)$, dovoljno je na tom mjestu zamijeniti u izrazom $-Kx$:

$$\begin{aligned} f(y, \dot{y}, -Kx, w) = & \begin{bmatrix} l_1(m_1 + m_2)\dot{\theta}_1^2 \sin \theta_1 + m_2 l_2 \dot{\theta}_2^2 \sin \theta_2 \\ -l_1 l_2 m_2 \dot{\theta}_2^2 \sin(\theta_1 - \theta_2) + g(m_1 + m_2)l_1 \sin \theta_1 \\ l_1 l_2 m_2 \dot{\theta}_1^2 \sin(\theta_1 - \theta_2) + g l_2 m_2 \sin \theta_2 \end{bmatrix} - \begin{bmatrix} d_1 \dot{q} \\ d_2 \dot{\theta}_1 \\ d_3 \dot{\theta}_2 \end{bmatrix} \\ & + \begin{bmatrix} -Kx \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}, \end{aligned} \quad (7.4)$$

gdje je, podsjetimo,

$$-Kx = -(k_1 q + k_2 \theta_1 + k_3 \theta_2 + k_4 \dot{q} + k_5 \dot{\theta}_1 + k_6 \dot{\theta}_2)$$

izraz u kojem je pojačanje K fiksno i unaprijed izračunato na *linearnom* modelu (Poglavlje 7.2), dok se u njega u *svakom* trenutku simulacije uvrštava stvarno, trenutno stanje $x(t)$ dobiveno rješavanjem punog *nelinearnog* sustava. Time se dobiva zatvorena petlja na punom nelinearnom modelu:

$$M(y)\ddot{y} = f(y, \dot{y}, -Kx, w), \quad (7.5)$$

odnosno, u obliku pogodnom za numeričku integraciju (npr. funkcijom `solve_ivp` u Pythonu):

$$\ddot{y} = M^{-1}(y) f(y, \dot{y}, -Kx, w).$$

Bitno je uočiti razliku u odnosu na jednadžbu (6.2) iz Poglavlja 6: ondje je $u = -Kx$ uvršten u *linearizirani* sustav $\dot{x} = Ax + Bu$, dajući točnu, zatvorenu formu $\dot{x} = (A - BK)x$. Ovdje se *isti* zakon upravljanja uvrštava u *izvorni, nelinearni* sustav. Pritom se koristi potpuno isto pojačanje K dobiveno LQR postupkom u Poglavlju 7.2, bez ikakvog ponovnog računanja ili prilagodbe za nelinearni slučaj. Rezultat više nije elegantan linearan izraz poput $A_{cl}x$, nego jednadžba koja i dalje sadrži sve izvorne trigonometrijske i kvadratne članove, samo s u zamijenjenim regulatorom. Upravo simulacija jednadžbe (7.5) kroz vrijeme (za neki početni otklon $\theta_1(0), \theta_2(0) \neq 0$) pokazuje uspijeva li regulator, dizajniran na pojednostavljenom linearnom modelu, stvarno stabilizirati pravi sustav.

8 | Simulacija na nelinearnom modelu i rezultati

U ovom poglavlju LQR regulator dizajniran u Poglavlju 7 primjenjuje se na **puni, nelinearni** model sustava iz Poglavlja 3.1, kako je najavljeno u Poglavlju 7.4. Cilj je provjeriti stabilizira li regulator, dizajniran na aproksimiranom (linearnom) modelu, stvarni sustav, te odrediti do koje mjere početni otklon smije narušiti pretpostavku malih kuteva iz Poglavlja 3.2, a da regulator i dalje uspješno radi.

8.1 Postavljanje simulacije

Nelinearna jednačba gibanja (7.5) rješava se koristeći funkciju `solve_ivp` iz Python paketa `scipy`, uz LQR pojačanje K izračunato u Poglavlju 7.2. Testirana su tri različita početna otklona $(\theta_1(0), \theta_2(0))$, kako bi se ispitala granica valjanosti regulatora: $(1^\circ, -1^\circ)$, $(10^\circ, -10^\circ)$ i $(20^\circ, -20^\circ)$, sve uz nulti početni položaj kolica i nulte početne brzine. Puni kod simulacije prikazan je u Listingu 8.1.

```
1 import numpy as np
2 from scipy.linalg import solve_continuous_are
3 from scipy.integrate import solve_ivp
4 import matplotlib.pyplot as plt
5 import matplotlib.animation as animation
6
7 #
8 # 1) FIZIKALNI PARAMETRI
9 #
10 m, m1, m2 = 1.0, 0.3, 0.2
11 l1, l2 = 0.3, 0.25
12 d1, d2, d3 = 0.1, 0.05, 0.05
13 g = 9.81
14
15 #
16 # 2) LINEARIZIRANI MODEL: xdot = A x + B u
17 #
```

```

18 M0 = np.array([[m+m1+m2, l1*(m1+m2), m2*l2],
19               [l1*(m1+m2), l1**2*(m1+m2), l1*l2*m2],
20               [l2*m2, l1*l2*m2, l2**2*m2]])
21 S = np.array([[0, 0, 0],
22               [0, g*(m1+m2)*l1, 0],
23               [0, 0, g*l2*m2]])
24 D = np.diag([d1, d2, d3])
25 Bu = np.array([[1.], [0.], [0.]])
26
27 RHS = np.hstack([S, D, Bu])
28 SOL = np.linalg.solve(M0, RHS)
29 M0inv_S = SOL[:, 0:3]
30 M0inv_D = SOL[:, 3:6]
31 M0inv_Bu = SOL[:, 6:7]
32
33 A = np.zeros((6, 6))
34 A[0:3, 3:6] = np.eye(3)
35 A[3:6, 0:3] = M0inv_S
36 A[3:6, 3:6] = -M0inv_D
37
38 B = np.zeros((6, 1))
39 B[3:6, :] = M0inv_Bu
40
41 #
=====

42 # 3) LQR REGULATOR
43 #
=====

44 Q = np.diag([1., 100., 100., 1., 10., 10.])
45 R = np.array([[1.]])
46 P = solve_continuous_are(A, B, Q, R)
47 Kctrl = np.linalg.solve(R, B.T @ P).flatten()
48
49 #
=====

50 # 4) PUNI Nelinearni Model
51 #
=====

52 def nonlinear_dynamics(t, x):
53     q, th1, th2, qd, th1d, th2d = x
54     u = -Kctrl @ x
55     M = np.array([
56         [m+m1+m2,                    l1*(m1+m2)*np.cos(th1),    m2*l2*np.
57         cos(th2)],
58         [l1*(m1+m2)*np.cos(th1), l1**2*(m1+m2),                l1*l2*m2
59         *np.cos(th1-th2)],
60         [l2*m2*np.cos(th2),          l1*l2*m2*np.cos(th1-th2), l2**2*m2
61         ]
62     ])
63     f = np.array([

```

```

61         l1*(m1+m2)*th1d**2*np.sin(th1) + m2*l2*th2d**2*np.sin(th2)
        + u,
62         -l1*l2*m2*th2d**2*np.sin(th1-th2) + g*(m1+m2)*l1*np.sin(th1
        ),
63         l1*l2*m2*th1d**2*np.sin(th1-th2) + g*l2*m2*np.sin(th2)
64     ]) - np.array([d1*qd, d2*th1d, d3*th2d])
65     yddot = np.linalg.solve(M, f)
66     return [qd, th1d, th2d, yddot[0], yddot[1], yddot[2]]
67
68 x0 = [0, np.deg2rad(1), np.deg2rad(-1), 0, 0, 0]
69 t_final = 8
70 fps = 30
71 t_eval = np.linspace(0, t_final, int(t_final*fps))
72 sol = solve_ivp(nonlinear_dynamics, [0, t_final], x0, t_eval=t_eval
73                 , max_step=0.01)
74 X = sol.y
75 #
=====

76 # 5) GRAFOVI (q, theta1, theta2, u kroz vrijeme)
77 #
=====


78 u_hist = -(Kctrl @ X)
79
80 fig1, axs = plt.subplots(4, 1, figsize=(7, 8), sharex=True)
81 axs[0].plot(sol.t, X[0]); axs[0].set_ylabel('q [m]'); axs[0].grid(
    True)
82 axs[1].plot(sol.t, np.rad2deg(X[1])); axs[1].set_ylabel(r'$\theta_1$ [deg]'); axs[1].grid(True)
83 axs[2].plot(sol.t, np.rad2deg(X[2])); axs[2].set_ylabel(r'$\theta_2$ [deg]'); axs[2].grid(True)
84 axs[3].plot(sol.t, u_hist); axs[3].set_ylabel('u [N]'); axs[3].
    set_xlabel('t [s]'); axs[3].grid(True)
85 fig1.tight_layout()
86 fig1.savefig('odzivi.png', dpi=120)

```

Listing 8.1: Simulacija zatvorene petlje na punom nelinearnom modelu, s LQR regulatorom (dijelovi 1–5: parametri, linearizacija, LQR, nelinearna dinamika, simulacija i grafovi).


8.2 Rezultati simulacije

8.2.1 Sustav bez regulatora



Slika 8.1: Vremenski odziv sustava **bez** regulatora ($u = 0$), za isti početni otklon $\theta_1(0) = 1^\circ$, $\theta_2(0) = -1^\circ$ korišten u sljedećem primjeru.


Prije razmatranja djelovanja regulatora, korisno je vizualno potvrditi nestabilnost otvorene petlje utvrđenu u Poglavlju 5. Slika 8.1 prikazuje ponašanje sustava bez ikakvog upravljanja ($u = 0$), polazeći od istog, vrlo malog početnog otklona $\theta_1(0) = 1^\circ$, $\theta_2(0) = -1^\circ$ koji se u sljedećem primjeru uspješno stabilizira uz regulator. Bez regulatora, zbog prisutnog trenja i gravitacije, njihalo postupno gubi energiju i oko $t \approx 5$ s smiruje se na $\theta_1 \approx 180^\circ$, $\theta_2 \approx -180^\circ$, u visećem, prirodno stabilnom položaju, suprotnom od uspravnog položaja koji je cilj ovog rada.

8.2.2 Mali početni otklon: 1° 

Slika 8.2: Vremenski odziv sustava za početni otklon $\theta_1(0) = 1^\circ$, $\theta_2(0) = -1^\circ$.

Za mali početni otklon (Slika 8.2) regulator sustav vraća u ravnotežu glatko i brzo: kutevi θ_1, θ_2 smiruju se na gotovo nulu unutar otprilike 4 sekunde, a upravljačka sila ostaje malena (ispod 7 N). Kolica se pritom pomaknu za tek nekoliko centimetara prije povratka blizu polazne pozicije. Ovo je ponašanje u skladu s očekivanjima – za male kuteve, aproksimacija iz Poglavlja 3.2 vrlo je precizna, pa regulator dizajniran na linearnom modelu radi gotovo identično kao na pravom, nelinearnom sustavu.


8.2.3 Umjeren početni otklon: 10°



Slika 8.3: Vremenski odziv sustava za početni otklon $\theta_1(0) = 10^\circ$, $\theta_2(0) = -10^\circ$.

Za deset puta veći početni otklon (Slika 8.3) regulator i dalje uspješno stabilizira sustav, no ponašanje postaje znatno izraženije: kolica se pomiču i preko jednog metra prije povratka prema polaznoj poziciji, kutevi prolazno prebace i do 30° prije konačnog smirivanja (do otprilike 4–5 sekundi), a potrebna upravljačka sila raste na gotovo 65 N. Iako je ovo znatno grublji odziv nego u prethodnom slučaju, sustav se i dalje uspješno vraća u uspravan položaj. Linearna aproksimacija je ovdje već primjetno manje precizna, ali regulator je dovoljno robustan da svejedno stabilizira nelinearni sustav.

8.2.4 Velik početni otklon: 20°



Slika 8.4: Vremenski odziv sustava za početni otklon $\theta_1(0) = 20^\circ$, $\theta_2(0) = -20^\circ$

Za početni otklon od 20° (Slika 8.4) regulator ne uspijeva stabilizirati sustav: kutjevi θ_1, θ_2 i položaj kolica q divergiraju bez ograničenja (štapovi se kreću jako brzo rotirati, kolica se pomiču tisućama metara, a upravljačka sila doseže vrijednosti veće od 10 000 N), umjesto da konvergiraju prema nuli. Ovaj rezultat nije neuspjeh regulatora samog po sebi, nego izravna posljedica narušavanja pretpostavke na kojoj je čitav pristup zasnovan. Aproksimacije $\sin \theta \approx \theta$ i $\cos \theta \approx 1$ iz Poglavlja 3.2 za 20° više nisu dovoljno precizne, pa se linearni model na kojem je K dizajniran značajno razilazi od stvarne, nelinearne dinamike.

8.3 Zaključak simulacije

Rezultati simulacije potvrđuju da LQR regulator, dizajniran isključivo na temelju linearizacije oko uspravne ravnoteže (Poglavlje 3), uspješno stabilizira nelinearni

sustav dvostrukog obrnutog njihala na kolicima za početne otklone unutar okvirno $\pm 10^\circ$. Ti otkloni pokrivaju sve realistične scenarije poremećaja navedene kao cilj rada (npr. vjetar ili čovjek koji lagano dodirne jedan od štapova). Istovremeno, simulacija jasno pokazuje i granicu valjanosti ovog pristupa. Za otklone reda veličine 20° , narušavanje pretpostavke malih kuteva dovodi do sustava koji se ne stabilizira. Ova simulacija izravno potvrđuje teorijsko upozorenje iz Poglavlja 3.2. Linearizirani model, a time i svaki regulator izveden iz njega, vrijedi samo u okolini ravnotežne točke. Sustav je uspješno stabiliziran unutar realnog, očekivanog raspona poremećaja.

Literatura

- [1] J. P. HESPANHA, *Linear Systems Theory*, nastavni materijali, University of California, Santa Barbara, dostupno na https://www.academia.edu/13106698/linear_systems_theory_Joao_P_Hespanha
- [2] *Equations of motion for an inverted double pendulum on a cart (in generalized coordinates)*, nastavni materijal, kolegij Kontrolltheorie, Technische Universität Berlin, 2012, dostupno na https://www3.math.tu-berlin.de/Vorlesungen/SS12/Kontrolltheorie/matlab/inverted_pendulum.pdf
- [3] R. E. KALMAN, *On the General Theory of Control Systems*, Proceedings of the First International Congress of the International Federation of Automatic Control (IFAC), Butterworths, London, 1960, 491–502.
- [4] J.-M. CORON, *Control and Nonlinearity*, Mathematical Surveys and Monographs, **136**, American Mathematical Society, Providence, 2007.
- [5] J. CARRASCO, *State-Space Control*, nastavni materijali, University of Manchester, 2016, dostupno na https://personalpages.manchester.ac.uk/staff/joaquin.carrasco/SS_notes.pdf
- [6] A. J. LAUB, *A Schur Method for Solving Algebraic Riccati Equations*, IEEE Transactions on Automatic Control, **24**(6)(1979), 913–921.
- [7] P. VIRTANEN ET AL., *SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python*, Nature Methods, **17**(2020), 261–272.

Sažetak

U ovom radu izgrađen je matematički model dvostrukog obrnutog njihala na pokretnim kolicima, polazeći od nelinearnih jednadžbi gibanja dobivenih Lagrange-ovom mehanikom. Model je lineariziran oko uspravne ravnotežne točke primjenom aproksimacije malih kuteva te zapisan u standardnom obliku prostora stanja $\dot{x} = Ax + Bu + Ew$. Nad dobivenim linearnim modelom provjerena je kontrolabilnost sustava Kalmanovim rang uvjetom te su analizirani polovi sustava, čime je pokazano da je otvorena petlja sustava nestabilna. Regulator stanja dizajniran je metodom linearno-kvadratne regulacije (LQR). Dobiveni regulator naposljetku je primijenjen na puni, nelinearni model sustava te testiran za nekoliko različitih početnih otklona, čime je potvrđeno da sustav uspješno stabilizira stvarnu, nelinearnu dinamiku unutar realnog raspona poremećaja, uz eksperimentalno utvrđenu granicu valjanosti linearne aproksimacije.

Ključne riječi

dvostruko obrnuto njihalo, linearizacija, prostor stanja, kontrolabilnost, polovi sustava, LQR regulator, stabilizacija, simulacija

Simulation of Control of a Double Inverted Pendulum on a Cart

Summary

This thesis develops a mathematical model of a double inverted pendulum mounted on a moving cart, starting from the nonlinear equations of motion obtained via Lagrangian mechanics. The model is linearized around the upright equilibrium point using the small-angle approximation and written in the standard state-space form $\dot{x} = Ax + Bu + Ew$. The controllability of the resulting linear model is verified using the Kalman rank condition, and the system poles are analyzed, showing that the open-loop system is unstable. A state feedback controller is designed using the linear-quadratic regulator (LQR) method. The resulting controller is finally applied to the full nonlinear model of the system and tested for several initial angular displacements, confirming that it successfully stabilizes the true nonlinear dynamics within a realistic disturbance range, while also experimentally establishing the limits of validity of the linear approximation.

Keywords

double inverted pendulum, linearization, state space, controllability, LQR controller, stabilization, simulation

Životopis