



SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU

FAKULTET PRIMIJENJENE MATEMATIKE I INFORMATIKE

Sveučilišni preddiplomski studij Matematika i računarstvo

Simulacija upravljanja dvostrukim obrnutim njihalom na kolicima

ZAVRŠNI RAD

Mentor:

**izv. prof. dr. sc.
Zoran Tomljanović**

**doc. dr. sc.
Matea Ugrica Vukojević**

Kandidat:

Luka Kurtović

Osijek, 2026

Sadržaj

1	Uvod	1
2	Pretpostavke modela i oznake	3
2.1	Pretpostavke modela	3
2.2	Oznake	4
3	Matematički model i linearizacija sustava	5
3.1	Nelinearni model sustava	5
3.2	Linearizacija oko uspravne ravnoteže	6
3.3	Prikaz u prostoru stanja	6
4	Upravlјivost sustava	9
5	Polovi sustava	11
6	Regulacija stanja	13
6.1	Opći princip: povratna veza po stanju	13
6.2	Zatvorena petlja	13
7	LQR regulator	15
7.1	Formulacija LQR problema	15
7.2	Rješavanje algebarske Riccatijeve jednadžbe	16
7.3	Usporedba otvorene i zatvorene petlje	18
7.4	Provjera na punom nelinearnom modelu	19
8	Simulacija na nelinearnom modelu i rezultati	21
8.1	Postavljanje simulacije	21
8.2	Rezultati simulacije	24
8.2.1	Sustav bez regulatora	24
8.2.2	Mali početni otklon: 1°	25
8.2.3	Umjeren početni otklon: 10°	26
8.2.4	Velik početni otklon: 20°	27
8.2.5	Odziv na vanjsku smetnju	27
8.2.6	Područje atrakcije	29
8.3	Zaključak simulacije	30
	Literatura	31

Sažetak	33
Summary	35

1 | Uvod

Cilj ovoga rada je izraditi simulaciju upravljanja dvostrukim obrnutim njihalom na pokretnim kolicima, sposobnu stabilizirati sustav u uspravnom ravnotežnom položaju.


Problem stabilizacije njihala u uspravnom položaju jedan je od klasičnih problema u teoriji upravljanja. Kada se na kolica koja se gibaju vodoravno postavi jedan štap, dobije se obrnuto njihalo na kolicima. Dodavanjem još jednog, zgloбно povezanog štapa dobiva se dvostruko obrnuto njihalo na kolicima. Sustav je nelinearan, a njegovo uspravno ravnotežno stanje prirodno je nestabilno. U ovom radu dvostruko obrnuto njihalo na kolicima želi se dovesti u uspravno ravnotežno stanje djelujući isključivo na kolica. Ovakvi se modeli koriste i u praktičnim primjenama. Upravo se dvostruko njihalo može koristiti za modeliranje hodanja robota. Zamašna noga tijekom faze oslonca na drugoj nozi standardno se modelira kao dvostruko njihalo, pri čemu bedrena kost i potkoljenica odgovaraju njegovim štapovima, a kuk i koljeno zglobovima koji ih povezuju s tijelom.

Prvo se razmatra nelinearni model sustava preuzet iz nastavnog materijala [2]. Zatim se taj model linearizira oko uspravnog ravnotežnog stanja i zapisuje u standardnom obliku prostora stanja. Nad dobivenim linearnim modelom potom se provjerava upravljivost sustava i analiziraju polovi. Tada se uvodi opći princip regulacije povratnom vezom po stanju te dizajnira konkretan regulator. Djelovanje dobivenog regulatora naposljetku se provjerava na punom nelinearnom modelu sustava.

2 | Pretpostavke modela i oznake

2.1 Pretpostavke modela

Polazni nelinearni fizikalni model sustava u potpunosti je opisan u nastavnom materijalu [2], gdje je izveden Lagrangeovom mehanikom. U ovom radu taj se model preuzima kao fizikalna osnova, dok se za opći teorijski okvir i notaciju linearnih sustava upravljanja (prostor stanja, matrice A,B,E, pojam upravljivosti i stabilnosti) koristi knjiga Linear Systems Theory Joãoa P. Hespanhe [1]. U poglavljima koja slijede model iz [2] se stoga prevodi iz njegove izvorne notacije u standardni oblik prostora stanja kakav koristi [1], čime postaje pogodan za primjenu alata za analizu i dizajn regulatora opisanih u toj skripti.



Slika 2.1: Shematski prikaz dvostrukog obrnutog njihala na kolicima, preuzeto iz [2].

Fizikalni sustav opisan u [2] sastoji se od kolica mase m koja se mogu gibati isključivo vodoravno, na koje je zglobo pričvršćen prvi, štap duljine l_1 s koncentriranom masom m_1 na vrhu. Na vrh prvog štapa (koji je ujedno i dno drugog) zglobo je pričvršćen drugi štap duljine l_2 s koncentriranom masom m_2 na vrhu. Kutevi θ_1 i θ_2 mjere otklon pojedinog štapa od uspravnog (okomitog) položaja, kako je prikazano na Slici 2.1. Sustavom se upravlja isključivo silom u koja djeluje na kolica, dok w_1, w_2, w_3 predstavljaju vanjske smetnje (npr. vjetar ili gurkanje) koje djeluju na kolica i oba zgloba. d_1, d_2, d_3 predstavljaju koeficijente trenja kolica i oba zgloba.

2.2 Oznake

Fizikalni sustav i njegove veličine opisani su sljedećim oznakama.

Oznaka	Značenje
m	masa kolica
m_1	masa na vrhu prvog štapa
m_2	masa na vrhu drugog štapa
l_1	duljina prvog štapa
l_2	duljina drugog štapa
q	vodoravni položaj kolica
θ_1	kut odklona prvog štapa od okomice
θ_2	kut odklona drugog štapa od okomice
d_1, d_2, d_3	koeficijenti trenja (kolica, prvi zglobov, drugi zglobov)
u	upravljачka sila na kolica
w_1, w_2, w_3	vanjske smetnje (sile na q, θ_1, θ_2)
g	gravitacijsko ubrzanje

Poopćene koordinate, upravljački ulaz i vanjske smetnje sustava definirani su vektorima:

$$y = \begin{bmatrix} q \\ \theta_1 \\ \theta_2 \end{bmatrix}, \quad u \text{ (sila na kolica)}, \quad w = \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}.$$

Ravnotežni (uspravni) položaj sustava, oko kojeg će se kasnije provoditi linearizacija, dan je s (kolica mogu mirovati u bilo kojem položaju q_0 , pa je taj položaj proizvoljan):

$$y_0 = \begin{bmatrix} q_0 \\ 0 \\ 0 \end{bmatrix}.$$

Budući da su jednadžbe gibanja drugog reda (sadrže $\ddot{y}$), stanje sustava mora obuhvatiti i položaj i brzinu; definira se vektor stanja:

$$x = \begin{bmatrix} y \\ \dot{y} \end{bmatrix} = \begin{bmatrix} q \\ \theta_1 \\ \theta_2 \\ \dot{q} \\ \dot{\theta}_1 \\ \dot{\theta}_2 \end{bmatrix} \in \mathbb{R}^6.$$

3 | Matematički model i linearizacija sustava

Kako bismo mogli upravljati sustavom, potrebno je prvo razumjeti nelinearni model $M(y)\ddot{y} = f(y, \dot{y}, u, w)$, a zatim ga linearizirati u oblik $\dot{x} = Ax + Bu + Ew$ oko uspravne ravnoteže. Alati za dizajn regulatora koje ovdje koristimo primjenjivi su na linearnim modelima.

3.1 Nelinearni model sustava

Kao što je opisano u Poglavlju 2, primjenom Lagrangeove mehanike na sustav prikazan na Slici 2.1 dobivaju se jednačbe gibanja u matričnom obliku:

$$M(y)\ddot{y} = f(y, \dot{y}, u, w), \quad (3.1)$$

gdje je $M(y)$ matrica mase sustava:

$$M(y) = \begin{bmatrix} m + m_1 + m_2 & l_1(m_1 + m_2) \cos \theta_1 & m_2 l_2 \cos \theta_2 \\ l_1(m_1 + m_2) \cos \theta_1 & l_1^2(m_1 + m_2) & l_1 l_2 m_2 \cos(\theta_1 - \theta_2) \\ l_2 m_2 \cos \theta_2 & l_1 l_2 m_2 \cos(\theta_1 - \theta_2) & l_2^2 m_2 \end{bmatrix},$$

a $f(y, \dot{y}, u, w)$ vektor koji predstavlja sve sile (odnosno poopćene sile) koje djeluju na sustav - gravitacijske i centrifugalne sile, sile trenja, upravljačku silu te vanjske smetnje:

$$f(y, \dot{y}, u, w) = \begin{bmatrix} l_1(m_1 + m_2)\dot{\theta}_1^2 \sin \theta_1 + m_2 l_2 \dot{\theta}_2^2 \sin \theta_2 \\ -l_1 l_2 m_2 \dot{\theta}_2^2 \sin(\theta_1 - \theta_2) + g(m_1 + m_2) l_1 \sin \theta_1 \\ l_1 l_2 m_2 \dot{\theta}_1^2 \sin(\theta_1 - \theta_2) + g l_2 m_2 \sin \theta_2 \end{bmatrix} - \begin{bmatrix} d_1 \dot{q} \\ d_2 \dot{\theta}_1 \\ d_3 \dot{\theta}_2 \end{bmatrix} + \begin{bmatrix} u \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}.$$

Matrica $M(y)$ je invertibilna za sve y [2], pa se jednačba (3.1) može zapisati u eksplicitnom obliku $\ddot{y} = M^{-1}(y)f(y, \dot{y}, u, w)$, pogodnom za numeričku integraciju. Za dizajn regulatora potreban je linearni model, pa sustav u nastavku lineariziramo.

3.2 Linearizacija oko uspravne ravnoteže

Zadržavanjem samo članova prvog reda po $(\theta_1, \theta_2, \dot{\theta}_1, \dot{\theta}_2)$:

$$\sin \theta_i \approx \theta_i, \quad \cos \theta_i \approx 1, \quad \cos(\theta_1 - \theta_2) \approx 1, \quad \dot{\theta}_1^2, \dot{\theta}_2^2, \dot{\theta}_1 \dot{\theta}_2 \approx 0,$$

matrica mase $M(y)$ postaje konstantna matrica M_0 (ovisna isključivo o masama i duljinama):

$$M_0 = \begin{bmatrix} m + m_1 + m_2 & l_1(m_1 + m_2) & m_2 l_2 \\ l_1(m_1 + m_2) & l_1^2(m_1 + m_2) & l_1 l_2 m_2 \\ l_2 m_2 & l_1 l_2 m_2 & l_2^2 m_2 \end{bmatrix}.$$

Isto tako, svi članovi vektora $f(y, \dot{y}, u, w)$ koji sadrže $\dot{\theta}_1^2, \dot{\theta}_2^2$ ili $\dot{\theta}_1 \dot{\theta}_2$ nestaju, dok preostali $\sin \theta_i$ članovi prelaze u θ_i :

$$f_{lin}(y, \dot{y}, u, w) = \begin{bmatrix} 0 \\ g(m_1 + m_2)l_1 \theta_1 \\ gl_2 m_2 \theta_2 \end{bmatrix} - \begin{bmatrix} d_1 \dot{q} \\ d_2 \dot{\theta}_1 \\ d_3 \dot{\theta}_2 \end{bmatrix} + \begin{bmatrix} u \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}.$$

Prvi član desne strane prepoznaje se kao umnožak konstantne matrice S i vektora y , drugi kao umnožak dijagonalne matrice trenja D i vektora $\dot{y}$, a treći kao umnožak vektora B_u i skalara u :

$$\begin{aligned} f_{lin}(y, \dot{y}, u, w) = & \underbrace{\begin{bmatrix} 0 & 0 & 0 \\ 0 & g(m_1 + m_2)l_1 & 0 \\ 0 & 0 & gl_2 m_2 \end{bmatrix}}_S \underbrace{\begin{bmatrix} q \\ \theta_1 \\ \theta_2 \end{bmatrix}}_y - \underbrace{\begin{bmatrix} d_1 & 0 & 0 \\ 0 & d_2 & 0 \\ 0 & 0 & d_3 \end{bmatrix}}_D \underbrace{\begin{bmatrix} \dot{q} \\ \dot{\theta}_1 \\ \dot{\theta}_2 \end{bmatrix}}_{\dot{y}} \\ & + \underbrace{\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}}_{B_u} \underbrace{u}_u + \underbrace{\begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}}_w. \end{aligned}$$

Uvrštavanjem ovog lineariziranog f_{lin} natrag u jednadžbu gibanja (3.1) (uz $M(y) \rightarrow M_0$ kako je pokazano ranije), dobiva se potpuno linearna jednadžba (bez trigonometrijskih funkcija i kvadratnih članova), no i dalje drugog reda te pomnožena matricom M_0 :

$$M_0 \ddot{y} = S y - D \dot{y} + B_u u + w. \quad (3.2)$$

3.3 Prikaz u prostoru stanja

M_0 je regularna matrica što slijedi iz invertibilnosti $M(y)$ za sve y , pokazane u [2]. Množenjem jednadžbe (3.2) s lijeva inverzom matrice M_0^{-1} izolira se najviša derivacija $\ddot{y}$:

$$\ddot{y} = M_0^{-1} S y - M_0^{-1} D \dot{y} + M_0^{-1} B_u u + M_0^{-1} w.$$

Inverz M_0^{-1} izračunat je simbolički (WolframAlpha) u zatvorenom obliku:

$$M_0^{-1} = \begin{bmatrix} \frac{1}{m} & -\frac{1}{l_1 m} & 0 \\ -\frac{1}{l_1 m} & \frac{m+m_1}{l_1^2 m m_1} & -\frac{1}{l_1 l_2 m_1} \\ 0 & -\frac{1}{l_1 l_2 m_1} & \frac{m_1+m_2}{l_2^2 m_1 m_2} \end{bmatrix}.$$

Izoliranjem najviše derivacije u jednadžbi (3.2) (množenjem s lijeva sa M_0^{-1}) dobiva se

$$\ddot{y} = M_0^{-1} S y - M_0^{-1} D \dot{y} + M_0^{-1} B_u u + M_0^{-1} w. \quad (3.3)$$

Uvodi se vektor stanja $x = [y; \dot{y}] \in \mathbb{R}^6$ (definiran u Poglavlju 2), odnosno raspisano po komponentama:

$$x = \begin{bmatrix} y \\ \dot{y} \end{bmatrix} = \begin{bmatrix} q \\ \theta_1 \\ \theta_2 \\ \dot{q} \\ \dot{\theta}_1 \\ \dot{\theta}_2 \end{bmatrix} \in \mathbb{R}^6.$$

Njegova derivacija po vremenu je

$$\dot{x} = \begin{bmatrix} \dot{y} \\ \ddot{y} \end{bmatrix},$$

gdje je gornji blok, $\dot{y}$, po samoj definiciji vektora stanja već poznat, a donji blok, $\ddot{y}$, dan je upravo jednadžbom (3.3). Uvrštavanjem dobivamo:

$$\dot{x} = \begin{bmatrix} \dot{y} \\ M_0^{-1} S y - M_0^{-1} D \dot{y} + M_0^{-1} B_u u + M_0^{-1} w \end{bmatrix}.$$

Ovaj izraz sada grupiramo po x , u te w :

$$\dot{x} = \underbrace{\begin{bmatrix} 0_{3 \times 3} & I_{3 \times 3} \\ M_0^{-1} S & -M_0^{-1} D \end{bmatrix}}_A \begin{bmatrix} y \\ \dot{y} \end{bmatrix} + \underbrace{\begin{bmatrix} 0 \\ M_0^{-1} B_u \end{bmatrix}}_B u + \underbrace{\begin{bmatrix} 0 \\ M_0^{-1} \end{bmatrix}}_E w.$$

Time je jednadžba drugog reda po y svedena na jednadžbu prvog reda po x , u standardnom obliku prostora stanja:

$$\dot{x} = Ax + Bu + Ew, \quad (3.4)$$

gdje su matrice A, B, E prepoznate gore:

$$A = \begin{bmatrix} 0_{3 \times 3} & I_{3 \times 3} \\ M_0^{-1} S & -M_0^{-1} D \end{bmatrix}, \quad B = \begin{bmatrix} 0 \\ M_0^{-1} B_u \end{bmatrix}, \quad E = \begin{bmatrix} 0 \\ M_0^{-1} \end{bmatrix}.$$

Promjena stanja sustava jednaka je, dakle, linearnoj kombinaciji trenutnog stanja, upravljačke sile i vanjskih smetnji. Ovaj model predstavlja polaznu točku za sve daljnje analize sustava: provjeru upravljivosti, analizu polova, te dizajn regulatora stanja.

4 | Upravlјivost sustava

Prije nego što krenemo u dizajn regulatora, potrebno je utvrditi je li sustav dobi-
ven u Poglavlju 3 uopće *upravlјiv*. Ovo je pitanje posebno relevantno jer sustav
ima samo jedan upravlјački ulaz (silu na kolica), dok stanje ima šest komponenti
 $x = [q, \theta_1, \theta_2, \dot{q}, \dot{\theta}_1, \dot{\theta}_2]^T$. Potrebno je provjeriti može li ta jedna sila, posredstvom
mehaničke sprege između kolica i oba štapa (kolica vuku prvi štap, prvi štap vuče
drugi), utjecati na sve komponente stanja, ili neka od njih ostaju "izvan dohvata".

Definicija 1 (vidjeti [4, Definicija 1.2]). Sustav $\dot{x} = Ax + Bu$ (poseban, vremenski
nepromjenjiv slučaj opće definicije za linearne vremenski promjenjive upravlјačke sustave)
je **upravlјiv** na $[T_0, T_1]$ ako za svaka dva stanja $x_0, x_1 \in \mathbb{R}^n$ postoji upravlјačka funkcija
 $u \in L^\infty([T_0, T_1]; \mathbb{R}^m)$ takva da rješenje $x \in C^0([T_0, T_1]; \mathbb{R}^n)$ jednadžbe $\dot{x} = Ax + Bu$,
uz početni uvjet $x(T_0) = x_0$, zadovoljava $x(T_1) = x_1$.

U ovom slučaju to znači da je sustav upravlјiv ako se silom u može, u konačnom
vremenu, dovesti iz bilo kojeg početnog stanja u bilo koje ciljano stanje.

Teorem 1 (vidjeti [4, Teorem 1.16]). Vremenski invarijantan linearni sustav upravlјa-
nja $\dot{x} = Ax + Bu$ je upravlјiv na $[T_0, T_1]$ ako i samo ako

$$\text{Span}\{A^i Bu ; u \in \mathbb{R}^m, i \in \{0, \dots, n-1\}\} = \mathbb{R}^n.$$

Štoviše, za bilo koje $T_0 < T_1$ i $\tilde{T}_0 < \tilde{T}_1$, sustav $\dot{x} = Ax + Bu$ upravlјiv je na $[T_0, T_1]$ ako
i samo ako je upravlјiv na $[\tilde{T}_0, \tilde{T}_1]$.

Ovaj rezultat u literaturi je poznat i kao Kalmanov rang uvjet upravlјivosti [3].

Uvjet iz teorema može se zapisati i u praktičnijem, ekvivalentnom obliku. Kad
 u prođe kroz cijeli $\mathbb{R}^m$, izraz $A^i Bu$ prolazi kroz sliku matrice $A^i B$, pa je $\text{Span}\{A^i Bu : u \in \mathbb{R}^m\} = \text{Im}(A^i B)$. Skup svih vektora oblika $A^0 Bu_0 + A^1 Bu_1 + \dots + A^{n-1} Bu_{n-1}$,
za proizvoljne $u_0, \dots, u_{n-1} \in \mathbb{R}^m$, jednak je stoga zbroju potprostora $\text{Im}(B) + \text{Im}(AB) + \dots + \text{Im}(A^{n-1}B)$. Standardno svojstvo linearne algebre kaže da je taj
zbroj slika jednak slici matrice dobivene vodoravnim nadovezivanjem (spajanjem
stupaca) svih tih matrica. Stoga se definira upravlјiva matrica

$$C := [B \quad AB \quad A^2B \quad \dots \quad A^{n-1}B] \in \mathbb{R}^{n \times (nm)},$$

pa je uvjet iz Teorema 1 ekvivalentan sa $\text{Im}(C) = \mathbb{R}^n$, odnosno (budući da je rang
matrice definiran kao dimenzija njene slike) s

$$\text{rank}(C) = n.$$

U nastavku rada koristi se upravo ovaj oblik uvjeta, jer je lakši za provjeru. Primijetimo da se pri konstrukciji matrice $\mathcal{C}$ koristi isključivo par (A, B) ; matrica E (kojom u model ulaze vanjske smetnje w) ne sudjeluje u provjeri upravljivosti, jer smetnje nisu veličina kojom mi upravljamo.

Za probne vrijednosti fizikalnih parametara

$$m = 1.0 \text{ kg}, \quad m_1 = 0.3 \text{ kg}, \quad m_2 = 0.2 \text{ kg}, \quad l_1 = 0.3 \text{ m}, \quad l_2 = 0.25 \text{ m}, \\ d_1 = 0.1 \text{ kg/s}, \quad d_2 = 0.05 \text{ kg m}^2/\text{s}, \quad d_3 = 0.05 \text{ kg m}^2/\text{s}, \quad g = 9.81 \text{ m/s}^2,$$

singularne vrijednosti upravljive matrice $\mathcal{C}$ (izračunate u Pythonu, funkcijom `numpy.linalg.svd`) iznose

$$\sigma_1 \approx 1.00 \times 10^6, \quad \sigma_2 \approx 4491, \quad \sigma_3 \approx 165, \quad \sigma_4 \approx 8.56, \quad \sigma_5 \approx 0.685, \quad \sigma_6 \approx 0.639.$$

Budući da su sve singularne vrijednosti strogo pozitivne, rang matrice $\mathcal{C}$ jednak je $\text{rank}(\mathcal{C}) = 6$ (izračunato funkcijom `numpy.linalg.matrix_rank`, koja rang određuje upravo brojanjem singularnih vrijednosti iznad numeričke granice). Sustav je za navedene parametre potpuno upravljiv, prema Teoremu 1.

Odabrane vrijednosti fizikalnih parametara predstavljaju fizikalno realističan red veličine za stolni (laboratorijski) uređaj ovog tipa – usporediv, primjerice, sa stvarnim komercijalnim sustavom Quanser za jednostruko obrnuto njihalo na kolicima (masa kolica 0.94 kg, masa njihala 0.23 kg, duljina 0.33 m). Vrijedi pritom napomenuti da upravljivost sustava (rang matrice $\mathcal{C}$ jednak $n = 6$) vrijedi za gotovo bilo koji smislen izbor strogo pozitivnih fizikalnih parametara – gubi se tek u fizikalno besmislenim rubnim slučajevima (npr. ako bi neka masa ili duljina štapova bila jednaka nuli) te u slučajevima gdje je prevelika razlika između štapova. Nadalje, kombinacija poput $m_1 = 3000 \text{ kg}$ i $m_2 = 0.2 \text{ kg}$, uz $l_1 = 0.3 \text{ m}$ i $l_2 = 4.5 \text{ m}$, ostala bi formalno upravljiva, no ne bi predstavljala fizikalno smislen niti izvediv uređaj. Odabrane vrijednosti stoga nisu birane radi same upravljivosti (koja bi vrijedila i za mnoge druge izbore), nego radi fizikalne uvjerljivosti sustava koji se modelira.

5 | Polovi sustava

Svojstvene vrijednosti matrice A sustava $\dot{x} = Ax$ nazivaju se **polovima** tog sustava. U ovom se radu pojmovi "pol" i "svojstvena vrijednost matrice A " koriste kao istoznačnice.

Teorem 2 (Teorem 8.1, vidjeti [1, poglavlje 8.3]). *Sustav $\dot{x} = Ax$ je asimptotski stabilan ako i samo ako svi polovi (svojstvene vrijednosti) matrice A imaju strogo negativan realni dio.*

Za probne vrijednosti parametara iz Poglavlja 4, numerički izračunate svojstvene vrijednosti matrice A iznose:

$$\begin{aligned}\lambda_1 &= 0, & \lambda_2 &= -14.574, & \lambda_3 &= -6.555, \\ \lambda_4 &= 7.608, & \lambda_5 &= 4.414, & \lambda_6 &= -0.067.\end{aligned}$$

Sustav $\dot{x} = Ax + Bu + Ew$ bez upravljanja ($u = 0$) je, prema Teoremu 2, nestabilan – matrica A ima dvije svojstvene vrijednosti sa strogo pozitivnim realnim dijelom (λ_4 i λ_5), pa nisu sve svojstvene vrijednosti strogo negativnog realnog dijela. Ovo odgovara obrnutom njihalu koje samo od sebe pada. Primijetimo također da ni $\lambda_1 = 0$ nije strogo negativna svojstvena vrijednost, prema Teoremu 2, ovo je samo po sebi dovoljno da sustav ne bude asimptotski stabilan. Ovaj granični pol odgovara položaju kolica q , budući da apsolutni položaj kolica fizikalno ne utječe ni na jednu silu ni moment u sustavu. Varijabla q se ne pojavljuje nigdje na desnoj strani jednadžbi gibanja. Čitav prvi stupac matrice A jednak je nuli, što odmah povlači svojstvenu vrijednost $\lambda = 0$, sa svojstvenim vektorom u smjeru q .

U nastavku rada (Poglavlje 6) ovaj se nedostatak ispravlja uvođenjem regulatora, koji djelovanjem na upravljačku silu u pomiče polove zatvorene petlje tako da svi imaju strogo negativan realni dio, čime se sustav stabilizira.

6 | Regulacija stanja

6.1 Opći princip: povratna veza po stanju

Regulator je pravilo po kojem automatski bira upravljački ulaz u na temelju trenutnog stanja sustava, kako bismo tu nestabilnost ispravili. Opći princip pritom je *povratna veza po stanju* (state feedback) [1, poglavlje 10.4]:

$$u = -Kx, \quad (6.1)$$

gdje je $K \in \mathbb{R}^{1 \times 6}$ red od šest brojeva (pojaćanja), po jedan za svaku komponentu stanja $x = [q, \theta_1, \theta_2, \dot{q}, \dot{\theta}_1, \dot{\theta}_2]^T$:

$$u = -(k_1 q + k_2 \theta_1 + k_3 \theta_2 + k_4 \dot{q} + k_5 \dot{\theta}_1 + k_6 \dot{\theta}_2).$$

Regulator u svakom trenutku "gleda" cijelo stanje sustava i računa silu koja ga gura natrag prema ravnoteži.

6.2 Zatvorena petlja

Uvrštavanjem zakona upravljanja (6.1) u jednadžbu sustava (3.4) (bez vanjske smetnje, $w = 0$) dobivamo:

$$\dot{x} = Ax + Bu = Ax + B(-Kx) = Ax - BKx = \underbrace{(A - BK)}_{=: A_{cl}} x. \quad (6.2)$$

Dobili smo novi sustav, s novom matricom $A_{cl} := A - BK$ ("cl" = closed loop). Cijeli je zadatak dizajna regulatora odabrati brojeve u K tako da A_{cl} bude stabilna matrica:

$$\dot{x} = A_{cl}x \text{ je stabilan} \iff \text{svi polovi od } A_{cl} \text{ imaju } \operatorname{Re}(\lambda) < 0.$$

Bitna napomena: preduvjet da takav K uopće postoji jest upravljivost para (A, B) , koju smo već pokazali u Poglavlju 4 (Teorem 1).

Preostaje pitanje kako konkretno odabrati brojeve unutar K tako da A_{cl} zaista bude stabilna matrica. U nastavku rada taj se izbor provodi metodom linearno-kvadratne regulacije (LQR), opisanom u Poglavlju 7, čime se dobiva pojaćanje K koje se uvrštava u jednadžbu zatvorene petlje (6.2).

7 | LQR regulator

U Poglavlju 6 uveden je opći princip povratne veze po stanju $u = -Kx$, no ostalo je otvoreno pitanje kako konkretno odabrati pojačanje K . U ovom poglavlju taj se izbor svodi na rješavanje optimizacijskog problema poznatog kao *linearno-kvadratni regulator* (LQR) [1, poglavlje 10.1].

7.1 Formulacija LQR problema

Tražimo regulator koji minimizira ukupnu "energiju izlaza" i "energiju upravljačkog signala", izraženu funkcionalom cijene:

$$J_{LQR} = \int_0^\infty (x(t)^T Q x(t) + u(t)^T R u(t)) dt. \quad (7.1)$$

1

Matrice Q i R sami biramo (uz pretpostavku $Q \succeq 0$, $R \succ 0$). One određuju koliko strogo penaliziramo otklon pojedine komponente stanja, odnosno utrošak upravljačke sile. Uz $Q = \text{diag}(q_1, \dots, q_6)$ i $x = [q, \theta_1, \theta_2, \dot{q}, \dot{\theta}_1, \dot{\theta}_2]^T$, svaku komponentu stanja kažnjavamo neovisno. U ovom radu odabrano je

$$Q = \text{diag}(1, 100, 100, 1, 10, 10), \quad R = 1,$$

čime su kutevi θ_1, θ_2 (najbitnije veličine za stabilizaciju) penalizirani 100 puta strože od položaja kolica q . Bitni su pritom isključivo omjeri unutar Q u odnosu na R , ne apsolutne vrijednosti – istovremeno skaliranje Q i R istim faktorom daje identično pojačanje K .

Kako bi se opravdao ovaj odabir matrica Q i R , izvršena je usporedba s dvije alternativne varijante, jednom koja kuteve penalizira još strože, i jednom koja štedi upravljačku silu. Na punom nelinearnom modelu, uz početni otklon $\theta_1(0) = 10^\circ$, $\theta_2(0) = -10^\circ$ dobivamo sljedeće:

¹Napomena o notaciji: Hespanha u [1] transponiranje označava apostroфом, x' , umjesto uobičajenog x^T koji koristimo u ovom radu – oznake su ovdje matematički istovjetne jer je $x \in \mathbb{R}^n$. Nadalje, opća LQR formula u [1, poglavlje 10.1] zapisana je preko *reguliranog izlaza* $y = Cx$, gdje se matrica C bira proizvoljno; u ovom se radu koristi poseban slučaj $C = I$ (penalizira se cijelo stanje izravno), pa je regulirani izlaz jednak samom stanju, $y = x$ – ovime se ujedno izbjegava sudar oznake y s već definiranim vektorom poopcenih koordinata $y = [q, \theta_1, \theta_2]^T$ iz Poglavlja 2, pa se u ovom radu umjesto Hespanhinog y dosljedno piše x .

Q, R	$\max \theta_1 $	$\max \theta_2 $	$\max u $	trud $\int u^2 dt$	$t_{\text{smirivanja}}$
$(1, 100, 100, 1, 10, 10), 1$	33.2°	22.3°	62.6 N	220.2	2.32 s
$(1, 500, 500, 1, 20, 20), 1$	31.5°	20.6°	77.5 N	244.4	2.47 s
$(1, 20, 20, 1, 5, 5), 1$	34.3°	23.2°	56.6 N	225.1	2.14 s

Strože penaliziranje kuteva daje manje maksimalne otklone te sporije smirivanje, no uz osjetno veću potrebnu silu (77.5 N naspram 62.6 N, skoro 24% više) i veći ukupni trud regulatora. Treći redak (slabije penaliziranje) ima najmanju vršnu silu (56.6 N), ali veći ukupni trud od odabrane varijante (225.1 naspram 220.2). Razlog leži u tome što slabija kazna na otklon stanja usporava asimptotsko približavanje ravnotežnom stanju. Iako sustav relativno brzo uđe unutar grube tolerancije otklona ($t_{\text{smirivanja}} = 2.14$ s), preostale, male oscilacije oko ravnoteže potom sporije trnu, pa mala, ali neprestana upravljačka sila djeluje kroz veći dio trajanja simulacije. Budući da trud mjeri integral u^2 kroz cijelo vrijeme simulacije, taj produljeni "rep" male, ali ustrajne sile na kraju nadmaši uštedu ostvarenu nižom vršnom silom. Odabrana varijanta predstavlja razuman kompromis, dovoljno strogo penalizira kuteve da budu prioritet, uz vršnu silu i ukupan trud manje ili usporedive s obje alternative.

7.2 Rješavanje algebarske Riccatijeve jednadžbe

Prije primjene sljedećeg teorema, vrijedi napomenuti da za $Q \succeq 0$, $R \succ 0$ i upravljiv par (A, B) , postoji jedinstveno jedinstveno stabilizirajuće rješenje P . Upravlјivost našeg sustava već je pokazana u Poglavlju 4, a matrice Q, R odabrane su pozitivno definitnima (Poglavlje 7.1), pa su svi uvjeti za postojanje takvog P zadovoljeni.

Teorem 3 (Teorem 10.1, vidjeti [1, poglavlje 10.4]). *Pretpostavimo da postoji simetrično rješenje P algebarske Riccatijeve jednadžbe (ARE)*

$$A^T P + PA + C^T Q C - P B R^{-1} B^T P = 0$$

za koje je $A - B R^{-1} B^T P$ stabilna matrica. Tada zakon upravljanja $u = -Kx$, $K = R^{-1} B^T P$, stabilizira zatvorenu petlju i pritom minimizira LQR kriterij J_{LQR} .

Uz $C = I$, vrijedi $C^T Q C = Q$, pa se ARE jednadžba iz teorema svodi na oblik korišten u nastavku rada:

$$A^T P + PA + Q - P B R^{-1} B^T P = 0. \quad (7.2)$$

Optimalno rješenje LQR problema, prema Teoremu 3, ima oblik povratne veze po stanju:

$$u = -Kx, \quad K = R^{-1} B^T P, \quad (7.3)$$

gdje je P rješenje jednadžbe (7.2). Primijetimo da je $A - B R^{-1} B^T P = A - BK = A_{cl}$ iz Poglavlja 6. Uvjet teorema time izravno jamči da je dobivena zatvorena petlja stabilna, u skladu s Teoremom 2.

Jednadžba (7.2) se ne rješava ručno, standardni je pristup preko Hamiltonove matrice [6], implementiran u gotovim funkcijama poput `solve_continuous_are` u Pythonu (paketa SciPy [7]), koja je i korištena za numerički izračun P , a time i K , u ovom radu.

Pogledajmo utjecaj odabira Q i R na regulator K .

Promotrimo kako se pojačanje K mijenja kada q_2 varira, dok se ostale veličine drže fiksnima. Tablica 7.1 prikazuje učinak variranja isključivo q_2 (težine na θ_1), uz $q_1 = 1, q_3 = 100, q_4 = 1, q_5 = 10, q_6 = 10$ i $R = 1$ fiksne:

q_2	k_1	k_2	k_3	k_4	k_5	k_6
50	1	-165.10	187.89	2.84	-7.94	14.80
100	1	-167.35	191.39	2.89	-7.98	15.09
200	1	-171.55	197.92	2.96	-8.05	15.64
400	1	-179.05	209.58	3.10	-8.18	16.61
800	1	-191.66	229.20	3.32	-8.38	18.25

Tablica 7.1: Utjecaj težine q_2 (na θ_1) na pojačanje K , uz ostale težine fiksne.

Iako se povećava isključivo q_2 , rastu sve komponente K (osim k_1). To je u skladu s ranije izvedenom formulom $k_1 = \sqrt{q_1/R}$ (Poglavlje 7.3), koja ovisi isključivo o q_1 .

Tablica 7.2 prikazuje analogan učinak variranja R , uz $Q = \text{diag}(1, 100, 100, 1, 10, 10)$ fiksno:

R	k_1	k_2	k_3	k_4	k_5	k_6
0.5	1.414	-191.58	226.08	3.93	-8.71	18.10
1.0	1.000	-167.35	191.39	2.89	-7.98	15.09
2.0	0.707	-152.16	169.32	2.16	-7.56	13.17
4.0	0.500	-142.91	155.56	1.65	-7.33	11.97
8.0	0.354	-137.34	146.96	1.27	-7.22	11.22

Tablica 7.2: Utjecaj težine R na pojačanje K , uz Q fiksno.

Kako R raste, sve komponente K padaju. Vrijednosti k_1 pritom u potpunosti prate formulu $k_1 = \sqrt{q_1/R}$: za $R = 0.5$, $\sqrt{1/0.5} = 1.414$; za $R = 8$, $\sqrt{1/8} = 0.354$.

Tablica 7.3 prikazuje učinak skaliranja cijelog Q (svih šest težina istim faktorom), uz $R = 1$ fiksno:

faktor	k_1	k_2	k_3	k_4	k_5	k_6
0.5	0.707	-152.16	169.32	2.16	-7.56	13.17
1.0	1.000	-167.35	191.39	2.89	-7.98	15.09
2.0	1.414	-191.58	226.08	3.93	-8.71	18.10
4.0	2.000	-228.88	279.01	5.42	-9.88	22.70

Tablica 7.3: Utjecaj skaliranja cijele matrice Q istim faktorom, uz R fiksno, na pojačanje K .

Zaključak je kako sve komponente od K apsolutno rastu.

Za usporedbu, Tablica 7.4 prikazuje slučaj kada se i Q i R skaliraju istim faktorom istovremeno, pojačanje K tada ostaje potpuno nepromijenjeno:

faktor	k_1	k_2	k_3	k_4	k_5	k_6
0.5	1	-167.35	191.39	2.89	-7.98	15.09
1.0	1	-167.35	191.39	2.89	-7.98	15.09
2.0	1	-167.35	191.39	2.89	-7.98	15.09
4.0	1	-167.35	191.39	2.89	-7.98	15.09

Tablica 7.4: Utjecaj istovremenog skaliranja Q i R istim faktorom na pojačanje K .

Ovo numerički potvrđuje tvrdnju iz Poglavlja 7.1 da je za pojačanje K bitan isključivo omjer Q/R , ne apsolutne vrijednosti tih matrica.

7.3 Usporedba otvorene i zatvorene petlje

Za probne vrijednosti parametara iz Poglavlja 4, rješavanjem (7.2) dobiveno je pojačanje

$$K = \begin{bmatrix} 1 & -167.3473 & 191.3879 & 2.8852 & -7.9784 & 15.0899 \end{bmatrix}.$$

Svojstvene vrijednosti sustava prije i nakon uvođenja regulatora s ovim K iznose:

Otvorena petlja (bez regulatora)
0, -14.57, -6.55, 7.61, 4.41, -0.067

Zatvorena petlja ($A - BK$)
-17.15, -8.43 ± 1.47j, -3.55, -0.55 ± 0.43j

Svi polovi zatvorene petlje imaju $\text{Re}(\lambda) < 0$, pa je, prema Teoremu 2, sustav s ovim regulatorom asimptotski stabilan.

Vrijedno je primijetiti da je prva komponenta dobivenog pojačanja, $k_1 = 1$ egzaktna. To je izravna posljedica graničnog pola $\lambda_1 = 0$ uočenog u Poglavlju 5. Budući da varijabla q ne utječe ni na jednu jednadžbu gibanja (prvi stupac matrice A jednak je nuli), u $(1, 1)$ -elementu algebarske Riccatijeve jednadžbe (7.2) članovi $A^T P + PA$ iščezavaju u potpunosti, pa preostaje jednostavna relacija

$$q_1 - \frac{(B^T p_1)^2}{R} = 0, \quad p_1 := P e_1,$$

gdje je $q_1 = Q_{11}$, a e_1 prvi stupac jedinične matrice. Kako je $k_1 = R^{-1} B^T p_1$ (prva komponenta formule (7.3)), slijedi

$$k_1 = \sqrt{\frac{q_1}{R}}.$$

Za odabrane težine $q_1 = 1$, $R = 1$ (Poglavlje 7.1) to daje $k_1 = 1$ egzaktno.

7.4 Provjera na punom nelinearnom modelu

Pojačanje K dizajnirano je na *linear*nom modelu iz Poglavlja 3, koji je tek aproksimacija stvarnog sustava, valjana samo za male kuteve θ_1, θ_2 . Da bismo provjerili djeluje li regulator i na stvarnom, nelinearnom sustavu, isti se K uvrštava natrag u puni nelinearni model iz Poglavlja 3.1:

$$M(y)\ddot{y} = f(y, \dot{y}, u, w),$$

pri čemu se umjesto slobodno odabranog u sada koristi izraz dobiven regulatorom, $u = -Kx$, primijenjen na trenutno (nelinearno) stanje sustava. Rezultati ove provjere prikazani su u poglavlju 8.

Konkretno, budući da se upravljačka sila u u nelinearnom modelu pojavljuje samo u prvoj komponenti vektora $f(y, \dot{y}, u, w)$, dovoljno je na tom mjestu zamijeniti u izrazom $-Kx$:

$$\begin{aligned} f(y, \dot{y}, -Kx, w) = & \begin{bmatrix} l_1(m_1 + m_2)\dot{\theta}_1^2 \sin \theta_1 + m_2 l_2 \dot{\theta}_2^2 \sin \theta_2 \\ -l_1 l_2 m_2 \dot{\theta}_2^2 \sin(\theta_1 - \theta_2) + g(m_1 + m_2)l_1 \sin \theta_1 \\ l_1 l_2 m_2 \dot{\theta}_1^2 \sin(\theta_1 - \theta_2) + g l_2 m_2 \sin \theta_2 \end{bmatrix} - \begin{bmatrix} d_1 \dot{q} \\ d_2 \dot{\theta}_1 \\ d_3 \dot{\theta}_2 \end{bmatrix} \\ & + \begin{bmatrix} -Kx \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix}, \end{aligned} \quad (7.4)$$

gdje je, podsjetimo,

$$-Kx = -(k_1 q + k_2 \theta_1 + k_3 \theta_2 + k_4 \dot{q} + k_5 \dot{\theta}_1 + k_6 \dot{\theta}_2)$$

izraz u kojem je pojačanje K fiksno i unaprijed izračunato na *linear*nom modelu (Poglavlje 7.2), dok se u njega u *svakom* trenutku simulacije uvrštava stvarno, trenutno stanje $x(t)$ dobiveno rješavanjem punog *nelinearnog* sustava. Time se dobiva zatvorena petlja na punom nelinearnom modelu:

$$M(y)\ddot{y} = f(y, \dot{y}, -Kx, w), \quad (7.5)$$

odnosno, u obliku pogodnom za numeričku integraciju (npr. funkcijom `solve_ivp` u Pythonu):

$$\ddot{y} = M^{-1}(y) f(y, \dot{y}, -Kx, w).$$

Bitno je uočiti razliku u odnosu na jednadžbu (6.2) iz Poglavlja 6: ondje je $u = -Kx$ uvršten u *linearizirani* sustav $\dot{x} = Ax + Bu$, dajući točnu, zatvorenu formu $\dot{x} = (A - BK)x$. Ovdje se *isti* zakon upravljanja uvrštava u *izvorni, nelinearni* sustav. Pritom se koristi potpuno isto pojačanje K dobiveno LQR postupkom u Poglavlju 7.2, bez ikakvog ponovnog računanja ili prilagodbe za nelinearni slučaj. Rezultat više nije elegantan linearan izraz poput $A_{cl}x$, nego jednadžba koja i dalje sadrži sve izvorne trigonometrijske i kvadratne članove, samo s u zamijenjenim regulatorom. Upravo simulacija jednadžbe (7.5) kroz vrijeme (za neki početni otklon $\theta_1(0), \theta_2(0) \neq 0$) pokazuje uspijeva li regulator, dizajniran na pojednostavljenom linearnom modelu, stvarno stabilizirati pravi sustav.

8 | Simulacija na nelinearnom modelu i rezultati

U ovom poglavlju LQR regulator dizajniran u Poglavlju 7 primjenjuje se na **puni, nelinearni** model sustava iz Poglavlja 3.1, kako je najavljeno u Poglavlju 7.4. Cilj je provjeriti stabilizira li regulator, dizajniran na aproksimiranom (linearnom) modelu, stvarni sustav, te odrediti do koje mjere početni otklon smije narušiti pretpostavku malih kuteva iz Poglavlja 3.2, a da regulator i dalje uspješno radi.

8.1 Postavljanje simulacije

Nelinearna jednačba gibanja (7.5) rješava se koristeći funkciju `solve_ivp` iz Python paketa `scipy`, uz LQR pojačanje K izračunato u Poglavlju 7.2. Testirana su tri različita početna otklona $(\theta_1(0), \theta_2(0))$, kako bi se ispitala granica valjanosti regulatora: $(1^\circ, -1^\circ)$, $(10^\circ, -10^\circ)$ i $(20^\circ, -20^\circ)$, sve uz nulti početni položaj kolica i nulte početne brzine. Puni kod simulacije prikazan je u Listingu 8.1.

```
1 import numpy as np
2 from scipy.linalg import solve_continuous_are
3 from scipy.integrate import solve_ivp
4 import matplotlib.pyplot as plt
5 import matplotlib.animation as animation
6
7 #
8 # 1) FIZIKALNI PARAMETRI
9 #
10 m, m1, m2 = 1.0, 0.3, 0.2
11 l1, l2 = 0.3, 0.25
12 d1, d2, d3 = 0.1, 0.05, 0.05
13 g = 9.81
14
15 #
16 # 2) LINEARIZIRANI MODEL:  $\dot{x} = A x + B u$ 
17 #
```

```

18 M0 = np.array([[m+m1+m2, l1*(m1+m2), m2*l2],
19                [l1*(m1+m2), l1**2*(m1+m2), l1*l2*m2],
20                [l2*m2, l1*l2*m2, l2**2*m2]])
21 S = np.array([[0, 0, 0],
22                [0, g*(m1+m2)*l1, 0],
23                [0, 0, g*l2*m2]])
24 D = np.diag([d1, d2, d3])
25 Bu = np.array([[1.], [0.], [0.]])
26
27 RHS = np.hstack([S, D, Bu])
28 SOL = np.linalg.solve(M0, RHS)
29 M0inv_S = SOL[:, 0:3]
30 M0inv_D = SOL[:, 3:6]
31 M0inv_Bu = SOL[:, 6:7]
32
33 A = np.zeros((6, 6))
34 A[0:3, 3:6] = np.eye(3)
35 A[3:6, 0:3] = M0inv_S
36 A[3:6, 3:6] = -M0inv_D
37
38 B = np.zeros((6, 1))
39 B[3:6, :] = M0inv_Bu
40
41 #
=====

42 # 3) LQR REGULATOR
43 #
=====

44 Q = np.diag([1., 20., 20., 1., 5., 5.])
45 R = np.array([[1.]])
46 P = solve_continuous_are(A, B, Q, R)
47 Kctrl = np.linalg.solve(R, B.T @ P).flatten()
48
49 #
=====

50 # 4) PUNI Nelinearni Model
51 #
=====

52 def nonlinear_dynamics(t, x):
53     q, th1, th2, qd, th1d, th2d = x
54     u = -Kctrl @ x
55     M = np.array([
56         [m+m1+m2,                                l1*(m1+m2)*np.cos(th1),    m2*l2*np.
57         cos(th2)],
58         [l1*(m1+m2)*np.cos(th1), l1**2*(m1+m2),                                l1*l2*m2
59         *np.cos(th1-th2)],
60         [l2*m2*np.cos(th2),                                l1*l2*m2*np.cos(th1-th2), l2**2*m2
61         ]
62     ])
63     f = np.array([

```

```

61         l1*(m1+m2)*th1d**2*np.sin(th1) + m2*l2*th2d**2*np.sin(th2)
        + u,
62         -l1*l2*m2*th2d**2*np.sin(th1-th2) + g*(m1+m2)*l1*np.sin(th1
        ),
63         l1*l2*m2*th1d**2*np.sin(th1-th2) + g*l2*m2*np.sin(th2)
64     ]) - np.array([d1*qd, d2*th1d, d3*th2d])
65     yddot = np.linalg.solve(M, f)
66     return [qd, th1d, th2d, yddot[0], yddot[1], yddot[2]]
67
68 x0 = [0, np.deg2rad(10), np.deg2rad(-10), 0, 0, 0]
69 t_final = 8
70 fps = 30
71 t_eval = np.linspace(0, t_final, int(t_final*fps))
72 sol = solve_ivp(nonlinear_dynamics, [0, t_final], x0, t_eval=t_eval
        ,
73                 max_step=0.01, rtol=1e-9, atol=1e-11)
74 X = sol.y
75
76 #
=====

77 # 5) GRAFOVI (q, theta1, theta2, u kroz vrijeme)
78 #
=====


79 u_hist = -(Kctrl @ X)
80
81 fig1, axs = plt.subplots(4, 1, figsize=(7, 8), sharex=True)
82 axs[0].plot(sol.t, X[0]); axs[0].set_ylabel('q [m]'); axs[0].grid(
    True)
83 axs[1].plot(sol.t, np.rad2deg(X[1])); axs[1].set_ylabel(r'$\theta_1$ [deg]'); axs[1].grid(True)
84 axs[2].plot(sol.t, np.rad2deg(X[2])); axs[2].set_ylabel(r'$\theta_2$ [deg]'); axs[2].grid(True)
85 axs[3].plot(sol.t, u_hist); axs[3].set_ylabel('u [N]'); axs[3].
    set_xlabel('t [s]'); axs[3].grid(True)
86 fig1.tight_layout()
87 fig1.savefig('odzivi.png', dpi=120)
88 print("Graf odziva spremljen kao 'odzivi.png'")

```

Listing 8.1: Simulacija zatvorene petlje na punom nelinearnom modelu, s LQR regulatorom (dijelovi 1–5: parametri, linearizacija, LQR, nelinearna dinamika, simulacija i grafovi).

8.2 Rezultati simulacije


8.2.1 Sustav bez regulatora



Slika 8.1: Vremenski odziv sustava **bez** regulatora ($u = 0$), za isti početni otklon $\theta_1(0) = 1^\circ$, $\theta_2(0) = -1^\circ$ korišten u sljedećem primjeru.

Za razliku od preostalih rezultata u ovom poglavlju, koji koriste zatvorenu petlju prikazanu u Listingu 8.1 (regulator $u = -Kx$), Slika 8.1 dobivena je zasebnom, ovdje neprikazanom skriptom, gotovo identičnom Listingu 8.1, ali s upravljačkom silom eksplicitno postavljenom na $u = 0$ umjesto $u = -Kx$.


Prije razmatranja djelovanja regulatora, korisno je vizualno potvrditi nestabilnost uspravnog ravnotežnog položaja otvorene petlje utvrđenu u Poglavlju 5. Slika 8.1 prikazuje ponašanje sustava bez ikakvog upravljanja ($u = 0$), polazeći od istog, vrlo malog početnog otklona $\theta_1(0) = 1^\circ$, $\theta_2(0) = -1^\circ$ koji se u sljedećem primjeru uspješno stabilizira uz regulator. Bez regulatora, zbog prisutnog trenja i gravitacije, njihalo postupno gubi energiju i oko $t \approx 5$ s smiruje se na $\theta_1 \approx 180^\circ$, $\theta_2 \approx -180^\circ$, u visećem, prirodno stabilnom položaju, suprotnom od uspravnog položaja koji je cilj ovog rada.

8.2.2 Mali početni otklon: 1° 

Slika 8.2: Vremenski odziv sustava za početni otklon $\theta_1(0) = 1^\circ$, $\theta_2(0) = -1^\circ$.

Za mali početni otklon (Slika 8.2) regulator sustav vraća u ravnotežu glatko i brzo: kutevi θ_1, θ_2 smiruju se na gotovo nulu unutar otprilike 4 sekunde, a upravljačka sila ostaje malena (ispod 7 N). Kolica se pritom pomaknu za oko 25 centimetara prije povratka blizu polazne pozicije. Ovo je ponašanje u skladu s očekivanjima – za male kuteve, aproksimacija iz Poglavlja 3.2 vrlo je precizna, pa regulator dizajniran na linearnom modelu radi gotovo identično kao na pravom, nelinearnom sustavu.


8.2.3 Umjeren početni otklon: 10°



Slika 8.3: Vremenski odziv sustava za početni otklon $\theta_1(0) = 10^\circ$, $\theta_2(0) = -10^\circ$.

Za deset puta veći početni otklon (Slika 8.3) regulator i dalje uspješno stabilizira sustav, no ponašanje postaje znatno izraženije: kolica se pomiču i preko jednog metra prije povratka prema polaznoj poziciji, kutevi prolazno prebace i do 30° prije konačnog smirivanja (do otprilike 4–5 sekundi), a potrebna upravljačka sila raste na gotovo 65 N. Iako je ovo znatno grublji odziv nego u prethodnom slučaju, sustav se i dalje uspješno vraća u uspravan položaj. Linearna aproksimacija je ovdje već primjetno manje precizna, ali regulator je dovoljno robustan da svejedno stabilizira nelinearni sustav.

8.2.4 Velik početni otklon: 20°



Slika 8.4: Vremenski odziv sustava za početni otklon $\theta_1(0) = 20^\circ$, $\theta_2(0) = -20^\circ$


Za početni otklon od 20° (Slika 8.4) regulator ne uspijeva stabilizirati sustav: kutevi θ_1, θ_2 i položaj kolica q divergiraju, umjesto da konvergiraju prema nuli. Ovaj rezultat nije neuspjeh regulatora samog po sebi, nego izravna posljedica narušavanja pretpostavke na kojoj je čitav pristup zasnovan. Aproksimacije $\sin \theta \approx \theta$ i $\cos \theta \approx 1$ iz Poglavlja 3.2 za 20° više nisu dovoljno precizne. Kako će pokazati Poglavlje 8.2.6, ovaj se konkretan otklon ($\theta_1(0) = 20^\circ$, $\theta_2(0) = -20^\circ$) nalazi u **protufaznom** smjeru, za koji je granica valjanosti regulatora osjetno niža nego za istofazne otklone. Narušavanje pretpostavke malih kuteva stoga ovisi ne samo o *veličini*, već i o *smjeru* početnog otklona.

8.2.5 Odziv na vanjsku smetnju

Dosadašnji testovi (Poglavlja 8.2.2–8.2.4) provjeravali su djelovanje regulatora isključivo kroz početni otklon sustava, uz vanjsku smetnju w jednaku nuli. Budući

da su vektor smetnje w i pripadna matrica E već uvedeni u Poglavlju 2 kao dio punog modela sustava, provjerava se i djelovanje regulatora uz prisutnu smetnju $w \neq 0$.

Sustav polazi iz uspravne ravnoteže, a između $t = 2.0$ s i $t = 2.3$ s djeluje kratkotrajna smetnja $w_2 = 0.05$ N m – moment koji simulira, primjerice, udar vjetra na prvi štap njihala. Rezultat je prikazan na Slici 8.5.




Slika 8.5: Odziv sustava na kratkotrajnu vanjsku smetnju $w_2 = 0.05$ N m (crveno područje, $t \in [2.0, 2.3]$ s), polazeći iz uspravne ravnoteže.

Prije djelovanja smetnje sustav ostaje potpuno miran u ravnoteži. Sama smetnja izazove otklon kuteva, nakon čega regulator uspješno vraća sustav natrag u uspravan položaj. Ovime je potvrđeno da regulator dizajniran isključivo na temelju odziva na početni otklon jednako uspješno odbacuje i vanjske smetnje koje djeluju tijekom rada sustava.

8.2.6 Područje atrakcije

Granica uspješne stabilizacije nije opisiva jednim brojem već je područje atrakcije. Kako bi se takvo područje u prikazalo, testirana je gusta mreža od 11 211 cjelobrojnih parova $(\theta_1(0), \theta_2(0)) \in [-55^\circ, 55^\circ] \times [-50^\circ, 50^\circ]$. Za svaki par provedena je zasebna simulacija punog nelinearnog sustava, uz standardni LQR regulator (Poglavlje 7.2), i zabilježeno je stabilizira li se sustav ili divergira.

Za potrebe ove mreže od preko 11 000 simulacija korišten je nešto jednostavniji, računski jeftiniji kriterij stabilizacije. Sustav se smatra stabiliziranim ako $|\theta_1(t)|$ ostane ispod 90° kroz cijelih 6 sekundi simulacije. Ovaj kriterij provjerava isključivo θ_1 , ne i θ_2 , te ne jamči formalno da je sustav *asimptotski* stabiliziran unutar tog vremenskog prozora, već samo da nije divergirao.



Slika 8.6: Područje atrakcije LQR regulatora u ravнини $(\theta_1(0), \theta_2(0))$ – zeleno označava početne otklone za koje se sustav uspješno stabilizira, crveno one za koje divergira.

Dobiveno područje atrakcije (Slika 8.6) ima izduženi, približno paralelogramski oblik, gdje dulja dijagonala paralelograma približno leži na pravcu $\theta_1 = \theta_2$ (gdje se oba štapa naginju u istom smjeru). U smjeru pravca $\theta_1 = \theta_2$ regulator stabilizira znatno veće otklone nego u smjeru okomito na njega. Najudaljenije stabilne točke od ishodišta nalaze se oko $(\theta_1, \theta_2) \approx (51^\circ, 40^\circ)$ i $(-51^\circ, -40^\circ)$. Najudaljenije točke **nisu** točno na pravcu $\theta_1 = \theta_2$. Glavna os područja atrakcije je,

blago nagnuta u odnosu na pravac $\theta_1 = \theta_2$, što odražava fizikalnu razliku između dva štapa njihala ($m_1 = 0.3 \text{ kg} \neq m_2 = 0.2 \text{ kg}$, $l_1 = 0.3 \text{ m} \neq l_2 = 0.25 \text{ m}$).

Nasuprot, za protufazni otklon ($\theta_1(0) = d$, $\theta_2(0) = -d$, štapovi padaju u suprotnim smjerovima), granica stabilizacije leži između $d = 14^\circ$ i $d = 15^\circ$.

Uočljivo je da je područje atrakcije simetrično s obzirom na ishodište. Ovo se može objasniti logikom zrcaljenja. Zamislimo cijeli sustav zrcaljen slijeva nadesno: ako se otklon gdje oba štapa padaju, primjerice, udesno uspješno stabilizira, mora se jednako uspješno stabilizirati i potpuno zrcaljena situacija, gdje oba štapa padaju ulijevo za iste kuteve. Ništa u fizici sustava (gravitacija, mase, trenje) ne razlikuje "lijevo" od "desno". Regulator će u zrcaljenoj situaciji jednostavno gurati kolica u zrcaljenom smjeru, u svakom trenutku, i postići identičan, samo zrcaljen ishod. Upravo to odgovara zamjeni $(\theta_1, \theta_2) \rightarrow (-\theta_1, -\theta_2)$.

Fizikalno objašnjenje veće tolerancije u istofaznom otklonu leži u prirodi jedinog upravljačkog ulaza – sile na kolica. Kada oba štapa padaju u približno istom smjeru, ispravan pomak kolica djeluje korektivno na oba kuta istovremeno. Kada štapovi padaju u suprotnim smjerovima, ispravljanje jednog kuta pomicanjem kolica može pogoršati otklon drugog. U tom se slučaju, regulator nalazi pred znatno težim, međusobno suprotstavljenim zahtjevima, pa mu za uspješnu stabilizaciju ostaje znatno manje prostora.

8.3 Zaključak simulacije

Rezultati simulacije potvrđuju da LQR regulator, dizajniran isključivo na temelju linearizacije oko uspravne ravnoteže, uspješno stabilizira nelinearni sustav dvostrukog obrnutog njihala na kolicima za realistične scenarije poremećaja navedene kao cilj rada (npr. vjetar ili čovjek koji lagano dodirne jedan od štapova) – što je izravno potvrđeno simulacijom smetnje (Poglavlje 8.2.5).

Analiza područja atrakcije (Poglavlje 8.2.6) pokazala je da granica valjanosti regulatora ovisi o tome padaju li štapovi u istom smjeru ili suprotnom. Regulator podnosi znatno veće otklone kada oba štapa padaju u približno istom smjeru nego kada padaju u suprotnim smjerovima. Otklon $\theta_1(0) = 20^\circ$, $\theta_2(0) = -20^\circ$ testiran u Poglavlju 8.2.4 stoga predstavlja upravo protufazni slučaj (iznad granice stabilizacije za tu vrstu otklona), zbog čega se sustav ne uspijeva stabilizirati.

Literatura

- [1] J. P. HESPAÑA, *Linear Systems Theory*, Princeton University Press, Princeton, 2009.
- [2] *Equations of motion for an inverted double pendulum on a cart (in generalized coordinates)*, nastavni materijal, kolegij Kontrolltheorie, Technische Universität Berlin, 2012, dostupno na https://www3.math.tu-berlin.de/Vorlesungen/SS12/Kontrolltheorie/matlab/inverted_pendulum.pdf
- [3] R. E. KALMAN, *On the General Theory of Control Systems*, Proceedings of the First International Congress of the International Federation of Automatic Control (IFAC), Butterworths, London, 1960, 491–502.
- [4] J.-M. CORON, *Control and Nonlinearity*, Mathematical Surveys and Monographs, **136**, American Mathematical Society, Providence, 2007.
- [5] J. CARRASCO, *State-Space Control*, nastavni materijali, University of Manchester, 2016, dostupno na https://personalpages.manchester.ac.uk/staff/joaquin.carrasco/SS_notes.pdf
- [6] A. J. LAUB, *A Schur Method for Solving Algebraic Riccati Equations*, IEEE Transactions on Automatic Control, **24**(6)(1979), 913–921.
- [7] P. VIRTANEN ET AL., *SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python*, Nature Methods, **17**(2020), 261–272.

Sažetak

U ovom radu izgrađen je matematički model dvostrukog obrnutog njihala na pokretnim kolicima, polazeći od nelinearnih jednačbi gibanja dobivenih Lagrange-ovom mehanikom. Model je lineariziran oko uspravne ravnotežne točke primjenom aproksimacije malih kuteva te zapisan u standardnom obliku prostora stanja $\dot{x} = Ax + Bu + Ew$. Nad dobivenim linearnim modelom provjerena je upravljivost sustava Kalmanovim rang uvjetom te su analizirani polovi sustava, čime je pokazano da je otvorena petlja sustava nestabilna. Regulator stanja dizajniran je metodom linearno-kvadratne regulacije (LQR). Dobiveni regulator naposljetku je primijenjen na puni, nelinearni model sustava te testiran za nekoliko različitih početnih otklona, čime je potvrđeno da sustav uspješno stabilizira stvarnu, nelinearnu dinamiku unutar realnog raspona poremećaja, uz eksperimentalno utvrđenu granicu valjanosti linearne aproksimacije.

Ključne riječi

dvostruko obrnuto njihalo, linearizacija, prostor stanja, upravljivost, polovi sustava, LQR regulator, stabilizacija, simulacija

Simulation of Control of a Double Inverted Pendulum on a Cart

Summary

This thesis develops a mathematical model of a double inverted pendulum mounted on a moving cart, starting from the nonlinear equations of motion obtained via Lagrangian mechanics. The model is linearized around the upright equilibrium point using the small-angle approximation and written in the standard state-space form $\dot{x} = Ax + Bu + Ew$. The controllability of the resulting linear model is verified using the Kalman rank condition, and the system poles are analyzed, showing that the open-loop system is unstable. A state feedback controller is designed using the linear-quadratic regulator (LQR) method. The resulting controller is finally applied to the full nonlinear model of the system and tested for several initial angular displacements, confirming that it successfully stabilizes the true nonlinear dynamics within a realistic disturbance range, while also experimentally establishing the limits of validity of the linear approximation.

Keywords

double inverted pendulum, linearization, state space, controllability, LQR controller, stabilization, simulation